

RL/SFT 训练动力学机制解读

2026-06

RL/SFT 训练动力学机制解读

综合本地调研（统一理论 / 诊断 / 混合综述 30+ 篇）与 2025–2026 最新研究。本章不罗列方法，而是回答一个问题：当我们做 SFT 和 RL 时，模型参数、输出分布、熵在“物理上”到底发生了什么，以及这对 VLA 真机后训练意味着什么。

1. 核心对立：SFT「记忆/压缩」vs RL「探索/扩展」

源头是 Chu et al. 的标杆实证 [SFT Memorizes, RL Generalizes (arXiv:2501.17161, ICML 2025)]: 在 GeneralPoints（算术）和 V-IRL（导航）上做规则/视觉变体 OOD 测试，发现 SFT 倾向记住训练分布、OOD 即崩；以结果奖励训练的 RL 则能跨变体泛化，甚至改善底层视觉识别。

但这句口号已被 2025 下半年研究反复修正，需区分三层：

层面	SFT 在做什么	RL 在做什么
目标	最大化专家轨迹似然 $-\log p(y x)$	最大化期望奖励 $E[R]$
数据来源	off-policy（固定专家数据）	on-policy（自身采样 rollout）
分布效果	扩张/同质化（覆盖更多 mode）	压缩/锐化（集中到高奖励 mode）
泛化来源	模仿，易过拟合训练分布	偏置采样到正确路径，提升采样效率
熵	不直接约束，常使熵升高/漂移	系统性降低熵（探索预算被消耗）
风险	OOD 遗忘、格式锁死	熵坍塌、mode collapse、多样性丧失

物理直觉：SFT 是“把概率质量铺到老师走过的所有路径上”（拟合更宽分布）；RL 是“把质量从错误路径抽走、堆到对的路径上”（再分配，不创造新路径）。二者方向相反，这正是它们互补又互相覆盖的根因。

关键澄清：「SFT 记忆、RL 泛化」是现象级总结，不是机制级真理。§ 2/§ 5 给出更准确版本——SFT 的问题不在“记忆”而在“OOD 早峰后遗忘”，RL 的作用很大程度是“修复”而非凭空泛化。

2. 分布层面动力学：sharpening vs expansion

2.1 两个对偶现象

- **RL Squeezes / SFT Expands** [arXiv:2509.21128]: 1.5B–14B 推理模型上做 reasoning-graph 分析，RL 把推理功能集中到少数关键 step (concentrate)，SFT 把功能均摊到许多 step (homogenize)。

- **参数层面对偶——MIFO** (arXiv:2510.04454): **SFT 参数更新冗余且幅度大, RL 更新节俭且幅度小**, 故后续 SFT 会“覆盖”先前 RL 学到的东西。这解释了两阶段顺序敏感、需要参数冻结来保护 RL-critical 权重。

2.2 RL 到底“扩展”还是“只锐化”? ——本章最大争议(需向导师呈现两面)

观点 A (只锐化, 不创造) [Does RL Really Incentivize Reasoning Beyond the Base Model? arXiv:2504.13837, NeurIPS 2025]: **pass@1 RL 胜 base, 但 pass@k (大 k) base 反超**; RL 可解集是 base 可解集的子集; 训练越久 pass@1 升、pass@256 反降——**采样效率提升, 但能力边界收窄**。

观点 B (足够长能扩展) [ProRL, arXiv:2505.24864, NVIDIA]: 用 KL 控制 + 参考策略重置 + 多样任务训 2k+ step 后, 在 **base 怎么采都失败 (pass@k=0) 的问题上 RL 也能解**, 出现分布外新解。

调和: 短/常规 RL = 锐化 (A 对); 长程 + 强探索保持 (防熵坍塌) + 参考重置的 RL = 可能扩展 (B 对)。**决定 RL 是“锐化”还是“扩展”的开关, 是探索预算(熵)是否被维持——引出 § 4。**

机制图解 (文字版):

base 分布:  (宽, 含正确路径但稀疏)
 SFT 后:  (更宽更平, 铺满老师路径, 含 OOD 漂移)
 常规 RL 后:  (尖峰, 锐化到高奖励 mode, pass@k ↓)
 长程 RL:  (尖峰 + 偶发新峰 = 边界扩展)

3. 梯度与 token 层面动力学

机制最干净、对工程最可操作的一层。

3.1 SFT 的梯度: 全 token 均匀正梯度, 但隐含坏 reward

[DFT / On the Generalization of SFT: A RL Perspective with Reward Rectification (arXiv:2508.05629, ICLR 2026)]: 标准 SFT 梯度 $\equiv$ 一个**隐式奖励** = $1/p(y|x)$ 的策略梯度。模型越不确定 (p 小) 的 token 反而被赋予越大大有效奖励 $\rightarrow$ **逆概率加权 + 无界方差**, 这是 SFT 泛化差的根因。

DFT 修正 (一行代码): $\text{loss} = -p(y|x).\text{detach}() \cdot \log p(y|x)$ (标准为 $-\log p(y|x)$)。把有偏、概率依赖的不稳定更新校正为均匀加权的稳定更新, 使 SFT 获得接近 RL 的泛化。

物理直觉: SFT 默认“每个 token 同等重要”, 但梯度数学上把权重偷偷压在低概率(难) token 上, 导致过拟合罕见模式; DFT 把这个偏置抹平。

3.2 RL 的梯度: 优势加权 + 负梯度

- RL (GRPO/PPO) 梯度 = **优势加权**: 正优势 token 推高、负优势 token 压低。SFT 只有正梯度 (只“抬”对的, 不“压”错的), 这是泛化差异的梯度级根源。
- **负梯度 = 锐化的真正动力** [On the Effect of Negative Gradient in GRPO, arXiv:2505.18830]: 对错误路径施加大负梯度, 在分布“谷地”产生 **squeezing effect**, 把质量从错误 mode 抽走——RL 锐化的微观机制, SFT 做不到。
- 副作用 **Lazy Likelihood Displacement**: 朴素惩罚错误响应所有 token 会让正确响应似然不升反降; 解法是按 token 贡献下调惩罚 (与 § 3.1 token 级重加权同思想)。

3.3 统一视角

[UPGE / HPT (arXiv:2509.04419)]: SFT、PPO、GRPO 都是同一个统一策略梯度估计器的特例，仅 4 组件取值不同。**SFT 不过是“优势恒为 +1、无负样本”的退化 RL**——这是“2026 年 SFT 不再是独立概念，而是 RL loss 的一个加权项”趋势的理论基座。

4. 熵动力学

4.1 熵坍塌是 RL 的核心瓶颈

[The Entropy Mechanism of RL for Reasoning LLMs (arXiv:2505.22617, PRIME-RL)]: 无干预 RL 中策略熵早期急剧下降，探索枯竭、性能饱和。拟合经验定律 $R = -a \cdot e^H + b$: 性能与熵满足指数关系，性能用熵“换”； $H \rightarrow 0$ 时性能触顶 $R = -a + b$ ，天花板在熵耗尽前就可预测。解法 Clip-Cov / KL-Cov: 只对高协方差 token 裁剪/KL 惩罚，保住探索。

物理直觉: 熵就是 RL 的探索预算，花光就跳不出当前 mode——这是 § 2.2 “常规 RL 只锐化”的微观解释。ProRL 能扩展边界，本质是通过 KL 控制 + 参考重置避免熵过早耗尽。

4.2 熵作为 SFT/RL 的判别信号

- [SRFT (arXiv:2506.19767)]: 用 policy entropy 动态调 SFT 权重——熵高（不确定）降 SFT 避免分布失配，熵低（自信）加大 RL 探索。**SFT 引起“粗粒度全局分布漂移”，RL 引起“细粒度选择性优化”，熵正好区分两个粒度。**
 - [RLSD / Self-Distilled RLVR (arXiv:2604.03128)]: 方向/幅度解耦能保持健康熵、避免 entropy collapse——环境奖励定方向、教师 logit gap 只调幅度，监督信号不挤压探索。
-

5. 灾难性遗忘与 OOD: RL 如何“修复”SFT

对 § 1 口号最重要的修正，核心 takeaway。

[RL Fine-Tuning Heals OOD Forgetting in SFT (arXiv:2509.12235)]: 真相不是“SFT 记忆 / RL 泛化”，而是 OOD 性能在 SFT 早期就达峰，随后随 ID 继续优化而下降 (OOD forgetting); RL 阶段在“恢复”被遗忘的能力，而非凭空创造。谱分析: 遗忘对应权重矩阵奇异向量的旋转（几何漂移），而奇异值基本不变（幅度没丢、方向丢了）。重要限制: RL 只能从有限范围的 SFT checkpoint 修复——SFT 过度了就救不回来。

与 [Quagmires (arXiv:2510.01624, NeurIPS 2025)] 的 1M GPU 小时结论呼应: 高 SFT 分数会误导你，极端情况下 SFT 后 RL 反比直接 RL 更差; 应改看 held-out 泛化 loss 和 pass@large-k。

物理直觉: RL 在这里是隐式正则化（类似 dropout），对抗 SFT 的 over-specialization——通过旋转奇异向量回到泛化方向，而非改变表征能量。所以 SFT 别练过头: 在 OOD 峰附近就切 RL。

VLM 反例提醒 [Synergy Dilemma, arXiv:2507.07562]: 在 reasoning VLM 上，两阶段/交替/渐进式 naive 混合三种都无真协同，只是不同维度 trade-off; 修复效应需 token 级细粒度控制 (CHORD/RLSD) 才稳。

6. 何时用 SFT、何时用 RL、何时混合

6.1 经验准则

场景	该做什么	依据
连格式都不对、0 奖励率高	先 SFT 稳定输出格式	2501.17161: SFT 是 RL 前提
已有格式、要泛化/采样效率	切 RL	2501.17161 / 2504.13837
难题所有 rollout 全失败 (0 梯度)	fallback SFT 或注入 expert prefix	SuperRL / BREAD
想要长期边界扩展	长程 RL + 维持熵 (KL 控制 + 参考重置)	ProRL + 2505.22617
最小改动提升 SFT 泛化	DFT 一行替换	2508.05629

6.2 三类自动切换信号（机制级）

1. **熵触发** (SRFT): 熵高压 SFT、熵低放 RL; 本质是按 “探索预算余额” 调度。
2. **梯度范数 + 散度触发** (SASR, arXiv:2505.13026): step-wise 比较两路梯度范数比与 KL 散度。
3. **rollout 正确率触发** (HPT/UPGE): 按当前题 rollout accuracy 决定走 SFT 还是 RL 信号。

趋势: 从 “两阶段顺序” → “按题/按 step 切换” → “单 step 双梯度统一 loss” (CHORD/DFT/UFT)。CHORD (ICLR 2026, arXiv:2508.11408, 已并入 ms-swift 4.2.0+) 把 SFT 当 on-policy RL 里一个动态加权辅助项, 对高散度 token 降权, 避免 off-policy 数据扰乱已学好的响应模式。

统一物理判据: SFT 还在补 base 缺的 “覆盖” (mode 不全) → 用 SFT; 覆盖已够、要把质量 “再分配” 到正确 mode 且仍有熵可花 → 用 RL; 两者都需要且互相干扰 → 用 token 级加权的单阶段混合, 让监督只调幅度、奖励定方向。

7. 对 VLA 真机后训练的启示

1. 「**RL 修复 SFT 遗忘**」直接成立且更关键。VLA 的 SFT (模仿演示) 同样 OOD 早峰后遗忘——换光照/物体/位姿就崩; RL 微调可作隐式正则修复。已有专门工作: [Continual VLA via RFT (arXiv:2602.10503)], [VLA-OPD (arXiv:2603.26666)] 均报告 **on-policy RL 比 SFT 更抗遗忘**。
2. **熵坍塌在动作空间更危险**。连续动作策略熵坍塌 = 动作多样性丧失 = mode collapse 到单一抓取姿态。VLA-OPD 用有界 **mode-seeking** 目标, 避开 Forward-KL 熵爆炸与 Hard-CE 过早熵坍塌。 $R = -a \cdot e^H + b$ 提醒: VLA RL 必须显式管熵。
3. **rollout 极贵** → **必须 off-policy + replay**。把专家演示当 “高质量 off-policy 样本” (LUFFY / PrefixRFT / BREAD)、用失败 episode 进 replay (MIFO 的 “失败 rollout → SFT buffer” 对应 VLA episodic memory), 是结构性约束, 也是 PLD 走 off-policy 的根本动因。
4. **梯度不对称** → **参数保护 + token 级重加权**。MIFO 的 “SFT 梯度大、覆盖 RL 梯度” 在 VLA 上很可能成立; 对应冻结 RL-critical 参数、对动作 token 做优势/幅度加权 (DFT reward rectification + RLSD 方向/幅度解耦可直接迁移)。
5. **不能只看 loss/成功率均值**。Quagmires 警告在 VLA 上加倍: SFT loss 降 ≠ 真机更好; 必须看 OOD 成功率、pass@large-k 式多样性指标。

一句话: VLA 后训练应是「SFT 求覆盖 (求准) → 在 OOD 峰附近切 RL 求锐化与修复 (求泛化), 全程显式管熵、用 off-policy replay 缓解 rollout 成本、用 token 级方向/幅度解耦让监督不挤压探索」。

参考文献

核心对立与分布动力学 - SFT Memorizes, RL Generalizes (arXiv:2501.17161, ICML 2025) — RL 跨变体泛化、SFT 过拟合; SFT 仍是 RL 格式前提。- RL Squeezes, SFT Expands (arXiv:2509.21128) — RL 集中到关键 step, SFT 均摊到多 step。- MIFO (arXiv:2510.04454) — SFT 更新冗余幅度大、覆盖 RL 节俭更新 (参数级不对称)。

RL 锐化 vs 扩展之争 - [Does RL Really Incentivize Reasoning Beyond the Base Model? \(arXiv:2504.13837, NeurIPS 2025\)](#) — RL 可解集是 base 子集,只提采样效率。- [ProRL \(arXiv:2505.24864\)](#) — 长程 RL + KL 控制 + 参考重置可扩展边界。

梯度 / token 层面 - [DFT — Reward Rectification for SFT \(arXiv:2508.05629, ICLR 2026\)](#) — SFT 梯度隐含 $1/p$ 坏 reward; 一行修正。- [On the Effect of Negative Gradient in GRPO \(arXiv:2505.18830\)](#) — 负梯度 squeezing effect = RL 锐化微观动力。- [UPGE / HPT — Unified View of LLM Post-Training \(arXiv:2509.04419\)](#) — 统一策略梯度估计器, SFT 是退化 RL。

熵动力学 - [The Entropy Mechanism of RL \(arXiv:2505.22617\)](#) — $R = -a \cdot e^H + b$, 性能用熵换; Clip-Cov/KL-Cov 防坍缩。- [SRFT \(arXiv:2506.19767\)](#) — 用熵区分 SFT 全局漂移 vs RL 细粒度优化并动态调权。

遗忘与 OOD 修复 / 诊断 - [RL Fine-Tuning Heals OOD Forgetting in SFT \(arXiv:2509.12235\)](#) — OOD 早峰后遗忘、RL 恢复; 奇异向量旋转、奇异值不变。- [Quagmires in SFT-RL Post-Training \(arXiv:2510.01624, NeurIPS 2025\)](#) — 高 SFT 分数误导; 改看 held-out loss / pass@large-k。- [Synergy Dilemma of Long-CoT SFT and RL \(arXiv:2507.07562\)](#) — VLM 上 naive 混合三法皆无真协同。

切换 / 统一混合 - [SASR \(arXiv:2505.13026\)](#) — 梯度范数比 + KL 散度做 step 级切换。- [CHORD \(arXiv:2508.11408, ICLR 2026\)](#) — SFT 作 on-policy RL 动态加权辅助项; 已并入 ms-swift。- [RLSD — Self-Distilled RLVR \(arXiv:2604.03128\)](#) — 方向/幅度解耦, 保持健康熵。

VLA 迁移 - [Continual VLA via Reinforcement Fine-Tuning \(arXiv:2602.10503\)](#) — on-policy RL 比 SFT 抗遗忘。- [VLA-OPD \(arXiv:2603.26666\)](#) — 有界 mode-seeking 目标避开熵爆炸/坍缩, 保动作多样性。

注: arXiv 编号中 26xx.xxxxx 为 2026 年预印本, 部分为本调研整理时的最新工作; 引用前请按实际发表信息核对。