

PLD 技术细节深读

2026-06

Contents

PLD (Probe-Learn-Distill) 技术细节深度报告	1
1. 问题设定与形式化目标	1
2. 残差策略 (Residual Policy) 的精确形式	2
3. Stage 1 (Probe + Learn): Cal-QL critic + 残差 actor	2
4. Stage 2 (Probing): 混合 rollout 的精确机制	2
5. Stage 3 (Distill): 蒸馏 SFT 与 “防遗忘在 Stage 2”	3
6. 双 Buffer + Cal-QL 的样本高效	3
7. 实验与消融硬数字	3
8. 审稿局限及真实技术根因	4
与 RPD 的一句话区分	4

PLD (Probe-Learn-Distill) 技术细节深度报告

论文: Self-Improving Vision-Language-Action Models with Data Generation via Residual RL (Xiao et al., NVIDIA / CMU / UC Berkeley / UT Austin, arXiv:2511.00091, ICLR 2026 Poster)

本文是主报告第 3 章的全细节支撑版，逐节核对论文原文（方法 § 3 + Eq.2 + Algorithm 1 + Appendix B.1 + Table 1/2/3/5/6 + Figure 11/13/14）。标 “（解读）” 者为精读笔记推断。

PLD 的一句话定位：冻结 VLA 主干，用 off-policy 残差 RL 训练一个轻量专家去 “接管” VLA 的失败状态，再用一种 “基策略探针 (probing) + 残差救场” 的混合 rollout 生成一批 “贴着 VLA 部署分布、且含纠错行为” 的数据，最后用标准 SFT 把这批数据蒸馏回 VLA 本体。全文真正的新颖点不是残差策略、也不是双 buffer（这些来自 ResiP / RLDP），而是用残差 RL 做 “部署对齐的数据策展 (data curation)”，训完即丢专家。

1. 问题设定与形式化目标

被训对象的形式。 PLD 把 VLA 当作 base policy π_b （默认 π_0 flow-matching head；也验证 OpenVLA 离散 token head）。策略消费 (o_t, g) 输出 $a_t = D_\phi(h_\theta(o_t, g))$ ， h_θ 为 VLM 主干、 D_ϕ 为动作头。动作 7-DoF（6-DoF delta 末端位姿 + 1-DoF 连续夹爪）。真机用 action chunking（GPU 装配 chunk size = 26、execution horizon = 15）。

控制过程。 goal-conditioned MDP，稀疏二元奖励 $r(s, a, g) = \mathbf{1}[d(\phi(s), g) \leq \varepsilon]$ 。off-policy 目标为标准 GCRL 折扣回报 $J(\pi) = \mathbb{E}[\sum_t \gamma^t r(s_t, a_t, g)]$ 。

为什么不能直接对 VLA 做 RL。 (i) sparse reward 下语言条件操作使 RL 不稳定且样本低效; (ii) 直接 RL fine-tune 大 VLA 资源极重——OpenVLA-OFT 在 LIBERO、batch 8 需 ~62.5 GB 单卡显存。故 PLD 选择 decoupled: 冻结 π_b , 只训轻量残差。

2. 残差策略 (Residual Policy) 的精确形式

执行动作 $\bar{a} = a_b + a_\delta$, $a_b \sim \pi_b$, $a_\delta \in [-\xi, \xi]$ 。残差是任务专属高斯策略 $\pi_\delta(\cdot|s, a_b)$ (条件于 s 与 VLA 想做的 a_b)。

参数化。3 层 MLP 高斯策略 (hidden 256、latent 256、Tanh、LayerNorm), 视觉用冻结 ResNetV1-10。单 task 5 GB VRAM peak、RTX 4090 可跑 (~10M 参数为解读)。

为什么 clip 到 $[-\xi, \xi]$ 。 ξ 太大 $\rightarrow$ 早期组合策略大幅偏离 π_b 、不稳定、早期崩 (Figure 13 action scale 1.0 早期塌陷); ξ 太小 $\rightarrow$ 探索不足、渐近差。结论: LIBERO $\xi = 0.5$ 、SimplerEnv $\xi = 0.1$ 。

为什么残差而非 LoRA / 直接 fine-tune。残差是结构独立高斯策略, 可用任意 off-policy 算法训 $\rightarrow$ 可维护 replay buffer、老 rollout 反复用。LoRA 嵌在 VLA 内部: 反向传播穿过整个 VLA (显存照炸)、对 flow/diffusion 头做最大化 Q 的 RL 极难。冻结主干同时根除灾难性遗忘——残差用完即弃。

3. Stage 1 (Probe + Learn): Cal-QL critic + 残差 actor

critic 目标 (Cal-QL, Appendix B.1):

$$\min_{\theta} \alpha \mathbb{E}_{s \sim \mathcal{D}, a \sim \pi} [\max(Q_{\theta}(s, a), V^{\mu}(s))] - \frac{1}{2} \mathbb{E}_{s, a \sim \mathcal{D}} [(Q_{\theta}(s, a) - \mathcal{B}^{\pi} \bar{Q}(s, a))^2].$$

第一项 calibrated CQL 保守项 (用 V^{μ} 做下界校准, 避免 CQL 过度低估); 第二项 TD-error。

TD 更新 (Eq.2) 用组合策略 bootstrap: $Q^{\pi}(s_t, \bar{a}_t) \leftarrow r + \gamma \mathbb{E}[Q^{\pi}_{\text{target}}(s_{t+1}, \bar{a}_{t+1})]$, $\bar{a} = a_b + a_\delta$ 。

actor 更新 通过最大化 SAC target (带 entropy, target entropy $-\text{act_dim}/2$, 自动调温), 不加 BC 正则——使专家不被数据质量/base 性能拖住。

warmup critic (§ 3.1): 先只用 π_b 数据初始化 Cal-QL critic、actor 不更新 (warmup 100 episodes)。意义: 防遗忘 + Cal-QL 预训练 critic 渐近更优、对 α 鲁棒 (Figure 14: Cal-QL > IQL > CQL, CQL 严重遗忘)。

UTD / ensemble: critic:actor = 2:1; Q ensemble 2 + Clipped Double Q + LayerNorm (RLPD trick 压制高 UTD 下 OOD Q 爆炸); Polyak 0.005。性能对 update frequency (1 $\rightarrow$ 500) 不敏感 (Figure 15)。

冻结 VLA: 梯度只过 π_δ 与 Q_θ , $\nabla_{\theta_{\text{VLA}}} = 0$ 。

4. Stage 2 (Probing): 混合 rollout 的精确机制

控制律: $\pi(s_t) = a_{\text{base}}$ 若 $t < \alpha T$ (VLA 单独走, 探针); $= a_{\text{base}} + a_\delta$ 若 $t \geq \alpha T$ (残差救场)。收集轨迹 = 前段起点 $s_0 \sim p_0^{\pi_b}$ (VLA 自身访问分布) + 后段专家从次优区恢复。**探针步只用于状态初始化、不进 replay buffer。**

为什么防遗忘 (support 语言): 全程用组合体采 ($\alpha=0$) $\rightarrow$ 数据是高度最优、单峰的专家轨迹, 集中在最优窄带, VLA 部署会访问的 OOD/失败状态 underrepresented $\rightarrow$ SFT 学不到实际失败的解。

Probing 把数据 support 拉回 VLA 访问分布, SFT 只需小幅更新。原文 § 3.2: 纯专家 “narrow distribution of unimodal expert behavior may leave OOD and failure states underrepresented... risks overfitting and harming robustness and generalization.”

α 消融 (Figure 11): 随 α 增大成功轨迹平均长度上升, fine-tuning 性能 $\alpha=0.6$ plateau, >0.6 下降。

Table 3 (数据来源对比, LIBERO-90 π_0 SFT, 按 coverage 的 Overall SR):

coverage	PLD Data	Base Rollout($\alpha=0$)	Human
0.1	0.314	0.103	0.272
0.3	0.470	0.068	0.419
0.6	0.637	0.328	0.611
0.8	0.745	0.344	0.694
1.0	0.871	0.488	0.815

未见任务 10% coverage 时 PLD 已 24.4% zero-shot, base rollout 几乎不泛化。

5. Stage 3 (Distill): 蒸馏 SFT 与 “防遗忘在 Stage 2”

SFT 目标 (按动作头实例化): token head $-\mathbb{E}[\log p_\theta(u_k|u_{<k}, x)]$; diffusion head $\mathbb{E}[\|\epsilon - \epsilon_\theta(\cdot)\|^2]$; flow head L_2 flow-matching。概念形式 $\mathcal{L}_{\text{SFT}} = -\mathbb{E}_{(s, a^*) \sim \mathcal{D}^{\text{PLD}}}[\log \pi_{\text{VLA}}(a^*|s)]$ 。实现 LoRA rank 32、 $8 \times L40$ 。

为什么防遗忘在 Stage 2: SFT loss 梯度幅度 $\propto$ 数据分布与当前策略分布的偏离。遗忘根因是 “SFT 数据离 π_b 太远 $\rightarrow$ loss 大 $\rightarrow$ 梯度大 $\rightarrow$ 覆盖通用能力”。PLD 数据起点在 π_b 访问分布上 $\rightarrow a^*$ 与 $\pi_b(\cdot|s)$ 差异小 $\rightarrow$ loss 初值小、梯度小、更新温和。KL 语言 (引 “RL” s Razor): PLD 数据 biased toward base $\boxtimes$ SFT 诱导 KL 小 $\boxtimes$ forgets less。与 MIFO 事后冻结参数本质不同: PLD 从数据侧根除遗忘。

蒸馏后无残差: 行为永久写进 VLA 权重, 部署 zero overhead, distilled generalist 超越 average specialist。

6. 双 Buffer + Cal-QL 的样本高效

对称回放 (承袭 RLPD): $\mathcal{B}_{\text{offline}}$ (π_b 成功 rollout, 永久锚定) + $\mathcal{B}_{\text{online}}$ (组合体 transition)。每 minibatch 各取一半。offline 一半防 Q 因 online 早期全失败而把所有动作判烂; online 一半提供新鲜信号。

250 $\times$ 复用: buffer 250k、训练 $\sim 250k$ actor steps, 一条真机数据进 buffer 后参与 $\sim 250k$ 次梯度更新。真机: Franka 200 条 teleop SFT 后 2 小时达 100%。

7. 实验与消融硬数字

LIBERO (Table 1): π_0 93.4 $\rightarrow$ **97.2** (Goal +7.9); OpenVLA 91.8 $\rightarrow$ **99.2** (Goal +15.7)。**SimplerEnv (Table 2):** Octo Avg 71.8 $\rightarrow$ **96.6**; Pick Carrot 43.3 $\rightarrow$ **93.9** (+50.6)。**真机 Franka:** peg insertion 30/30; cube pick-up 随机化 PLD 30/30 vs RLPD 16/30 vs Human 10/30。失败模式 (Figure 8): RLPD/Human 训出的策略把方块推进左上角卡死 (没访问过角落状态), PLD 探针到这些状态生成

recovery 救回。真机 unseen (Table 6): Pick Blue Cube(cluttered) PLD 28/30 vs Human 12/30。
YAM 双臂 GPU 装配: 4 stage 串联, 连续 1 小时无人介入循环。

ablation: α plateau@0.6 (Fig.11) ; action scale LIBERO 0.5/SimplerEnv 0.1 (Fig.13) ; Cal-QL>IQL>CQL (Fig.14); reward bias 大 bias(-1.0) 显著伤性能 $\rightarrow$ 用 0.0 (Fig.12); JSRL 部分 task 不收敛、PLD 全收敛 (Fig.17)。

超参 (Table 5): batch 256、buffer 250k、 γ 0.99、lr $3e-4$ 、AdamW、warmup 100、critic:actor 2、target entropy $-\text{act_dim}/2$ 、 ξ 0.5、Q ensemble 2、Polyak 0.005、ResNetV1-10、hidden 256、LayerNorm。

8. 审稿局限及真实技术根因

4 审稿 (F1ZL 8 / wXQ9 4 $\rightarrow$ support / yzFS 6 / BWyM 6), Accept(Poster)。

1. 只用 sparse binary reward (未解决): Cal-QL 学 0/1, 难训任务无梯度密度。
2. **competence threshold**——**base 必须够强**: 残差只在 a_b 邻域修正 + probing 依赖 base 走到有意义状态。base>80% $\rightarrow$ 99%, base<50% $\rightarrow$ 救不回 (Figure 10)。
3. **closed-loop 残差 vs open-loop chunking 蒸馏**: 训练逐步闭环、部署 chunk 开环, 闭环纠错被打包进 chunk, 高动态任务失效。
4. **per-task 残差无 skill 共享**: 90 task = 90 MLP, 训练成本线性增长。
5. **flat FIFO replay 无能力感知**: 不按 TD-error/语义价值优先保留。
6. **episode-level 信用分配**: reward 仅末尾 0/1, 放大对双 buffer + LayerNorm 依赖。
7. **“Self-Improving” 只跑一轮**: 多轮收益递减未实证。

rebuttal 说服点: 1h autonomous 真机 demo、competence threshold 定量边界、recovery-data ablation (去掉 recovery 数据策略卡 failure mode)、5 GB VRAM/task。

与 RPD 的一句话区分

同起点 (VLA SFT $\sim$ 60%) 但目标相反: **PLD 改 VLA 本体** (off-policy Cal-QL + 双 buffer + probing + 蒸馏, 真机可行, 部署单一 VLA); **RPD** (Jülg et al. IROS 2026) 训新小学生 (on-policy PPO + MSE 蒸馏 $\mathcal{L} = \mathcal{L}_{\text{PPO}} - \mathcal{L}_{\text{MSE}}$, 仿真 only, 百万样本, 部署 100M student, VLA 训完即扔)。PLD 选 off-policy 是因真机 rollout 太贵不能丢——不是 off-policy 更好, 而是真机没得选。