

RECAP 技术细节深读

2026-06

Contents

RECAP / $\pi^*0.6$ 技术机制精读报告	1
1. 框架: PRETRAIN $\rightarrow$ SPECIALIZE $\rightarrow$ ITERATE, 及 “每轮从 anchor 重训”	1
2. 奖励与 value function	2
3. Advantage 与二值 indicator	2
4. 策略训练: CFG 双支 + prefix 注入 + random drop	2
5. CFG 推理与 flow-matching 下界	3
6. 为什么绕开 PPO: AWR 视角与下界	3
7. 迭代微观机制: I_t flip	3
8. 实验	4
9. 与精读笔记的差异更正	4

RECAP / $\pi^*0.6$ 技术机制精读报告

论文: Physical Intelligence, $\pi^*0.6$: a VLA That Learns From Experience, arXiv:2511.14759v2 (2025-11-19, 未开源) 方法名: RECAP = RL with Experience and Corrections via Advantage-conditioned Policies

本文是主报告第 4 章的全细节支撑版。凡精读笔记与原文不一致处以原文为准并标注 (如 dropout 30% 非 50%、后训练 advantage 用 $N=50$ lookahead)。

定位: 把 episode 级 0/1 成功标签, 经分布式 value function 升级成 step 级 advantage, 再把 advantage 当作条件输入 (conditioning) 而非损失项 (loss) 注入策略, 用纯加权监督学习实现 self-improving, 完全绕开 PPO/REINFORCE。

1. 框架: PRETRAIN $\rightarrow$ SPECIALIZE $\rightarrow$ ITERATE, 及 “每轮从 anchor 重训”

Algorithm 1 (10 行):

```
1: 用 Eq.1 在  $D_{demo}$  上训  $V_{pre}$   $\quad \neg$  PRETRAIN (一次性,  $\pi_{pre}$  即  $\pi^*0.6$ )
2: 用 Eq.3 +  $V_{pre}$  训  $\pi_{pre}$   $\quad \neg$ 
3:  $D_{\ell} \leftarrow D_{demo}(\ell)$   $\quad \neg$  SPECIALIZE
4: 从  $V_{pre}$  训  $V0_{\ell}$  (Eq.1,  $D_{\ell}$ )  $\quad |$ 
5: 从  $\pi_{pre}$  训  $\pi0_{\ell}$  (Eq.3,  $V0_{\ell}$ )  $\quad \neg$ 
6: for  $k=1 \cdots K$ :  $\quad \neg$  ITERATE
7: 用  $\pi^{k-1}$  采数据并入  $D_{\ell}$   $\quad |$ 
8: 从  $V_{pre}$  训  $V^k$  (Eq.1, 整个  $D_{\ell}$ )  $\quad |$ 
```

9: 从 π_{pre} 训 π^k (Eq.3, V^k) |
 10: end for ┘

反直觉核心：第 8/9 行每轮都从 $V_{\text{pre}}/\pi_{\text{pre}}$ 重训，而非从上一轮增量更新。原文 V-D: “finetuned from the pre-trained checkpoint, rather than the policy and value from the last iteration ... useful for avoiding drift over multiple iterations.” 机制：从 π^{k-1} 增量更新会逐轮累积分布偏移（连续微调下的灾难性遗忘）；把 π_{pre} 当永久 anchor、每轮回原点，唯一在变的是数据池越来越好，改进由数据质量驱动而非参数漂移 → 多轮单调可控。

2. 奖励与 value function

Reward (Eq.5): $r_t = 0$ ($t = T$ 且 success) / $-C_{\text{fail}}$ ($t = T$ 且 failure, C_{fail} 大常数, 论文未给精确值) / -1 (otherwise)。无折扣下成功轨迹 MC return $R_t = \sum_{t' \geq t} r_{t'} = -(\text{剩余步数}) \rightarrow$ **value 学的是“到成功的负剩余步数”**，归一化 $[-1, 0]$ 。失败轨迹末步 $-C_{\text{fail}}$ 拉低 return → value 显式学会识别失败状态。

分布式 value (Eq.1): 小 VLM backbone (~670M)，输出 V 在 **201 bin** 上 softmax，对离散化 MC return 做交叉熵：

$$\min_{\phi} \mathbb{E}_{\tau} \left[\sum_{o_t} H(R_t^B(\tau), p_{\phi}(V|o_t, \ell)) \right], \quad V(o_t) = \sum_b p_{\phi}(V=b|o_t) v(b).$$

为什么分布式 + CE 而非 MSE: (i) return 多峰，MSE 压成条件均值丢模态；(ii) CE 把回归变分类、目标固定 one-hot、梯度有界、对失败极端负 return 鲁棒，MSE 对长尾大残差易震荡。**为什么 MC 而非 TD:** TD bootstrap 在大模型 + 异质 off-policy + 稀疏奖励下易发散（需 Cal-QL 一整套）；MC 无自举发散，代价是高方差且反映行为策略 return（非 V^* ），但 value 只用来算 advantage 做条件、不进 actor 反向传播，偏差可容忍——只需可靠的相对好坏信号。

3. Advantage 与二值 indicator

后训练 advantage (Appendix F, N=50 lookahead): $A^{\pi}(o_t, a_t) = \sum_{t'=t}^{t+49} r_{t'} + V(o_{t+50}) - V(o_t)$ 。
 预训练用纯 MC ($N = T$)。

indicator: $I_t = \mathbb{1}[A > \epsilon_{\ell}]$ 。阈值 per-task 校准：预训练约 30% 为正、微调约 40%、折衷 (demo 质量高) 约 10%。**为什么阈值而非推理期 β :** 高 CFG weight “drive action distribution to corners of support → aggressive behavior”，故把“该多优化”从推理期挪到训练期 ϵ_{ℓ} 。

三类数据不对称: demo 强制 $I_t = \text{True}$ (绕过 value)；human correction 强制 True (假设专家纠正总好)；autonomous 真按 $\mathbb{1}[A > \epsilon]$ (失败段多 False，教“别这么做”)。失败 episode 不丢——既训 value 又教策略避错。

4. 策略训练：CFG 双支 + prefix 注入 + random drop

目标 (Eq.3):

$$\min_{\theta} \mathbb{E}_{\mathcal{D}} \left[-\log \pi_{\theta}(a_t|o_t, \ell) - \alpha \log \pi_{\theta}(a_t|I_t, o_t, \ell) \right].$$

unconditional 支学行为平均; conditional 支学已知好坏标签下的策略。本质 = 对全部数据（成功 + 失败、好 + 坏）的加权/条件监督学习，无 PG、无 importance ratio、无 KL。

prefix 注入： $I_t = \text{True}$ 输入 “Advantage: positive”、否则 “negative”，位置在 ℓ 之后、动作之前 → 只影响动作 log-likelihood、不改架构。

random drop I_t (30%, 非笔记的 50%)： 30% 步训 unconditional、70% 训 conditional → 一个 trick 同训两模型省一遍 forward，等价替代权重 α (“randomly omit I_t instead of tuning α ")。这是 CFG 训练侧标准做法。

5. CFG 推理与 flow-matching 下界

闭式 (Eq.2)： $\hat{\pi} \propto \pi_{\text{ref}}(a|o, \ell) (\pi_{\text{ref}}(a|I, o, \ell) / \pi_{\text{ref}}(a|o, \ell))^\beta$ 。 $\beta = 1$ 退化为直接用 conditional 支 (单次 forward，默认部署)； $\beta > 1$ 锐化 improvement 方向 ($2 \times$ forward)。

flow score 外推 (Appendix E)： $\nabla_a \log \pi_\theta(a|o, \ell) + \beta (\nabla_a \log \pi_\theta(a|I, o, \ell) - \nabla_a \log \pi_\theta(a|o, \ell))$ — 与图像扩散 CFG 形式完全一致，“类别条件”换成 “Advantage: positive”。

下界 (Eq.4/9)： flow 无解析 $\log \pi$ ，用扩散 $\leftrightarrow$ flow 等价把 flow-matching MSE 当 log-likelihood 下界： $\log \pi_\theta(a|I, o, \ell) \geq \mathbb{E}[\log p_\theta(a^{\text{disc}}|\cdot) - \alpha_\eta \|\omega - a - f_\theta(a^{\eta, \omega}, I, o, \ell)\|^2]$ (离散 token 自回归似然 + 连续动作 flow MSE)。

6. 为什么绕开 PPO：AWR 视角与下界

regularized RL 目标 $\mathcal{J} = \mathbb{E}[\sum \gamma^t r_t] - \beta \mathbb{E}[D(\pi \| \pi_{\text{ref}})]$ 的经典解是 AWR $\tilde{\pi} \propto \pi_{\text{ref}} \exp(A/\beta)$ 。RECAP 不用它 (AWR “discard or significantly downweight a significant portion of the data → filtered imitation”)，而用 **less well-known result**： $\tilde{\pi} \propto \pi_{\text{ref}}(a|o) p(I|A)$ ，只要 $p(I|A)$ 是 advantage 单调递增函数即保证 $\mathcal{J}(\tilde{\pi}) \geq \mathcal{J}(\pi_{\text{ref}})$ (单调改进)，取阈值 delta 分布 + Bayes 重写得 Eq.2/Eq.3。整个推导只涉及监督式 log-likelihood，advantage 不进梯度。

维度	PPO	RECAP
数据	on-policy	off-policy/全离线，单池只增
advantage 进哪	loss/梯度	conditioning 通道 (prefix)
importance ratio	需 + clip	无
KL/信任域	需	无显式 (隐含在 anchor 重训 + 阈值)
flow 兼容	难	用下界天然兼容

实验 (Fig.11)： PPO (信任域收到 $\eta = 0.01$ 才稳但性能差)、AWR (策略慢、throughput 低) 均显著差于 RECAP。

7. 迭代微观机制： I_t flip

旧 episode (o_t, a_t, r_t) 永不变，但每轮从 V_{pre} 重训新 V^k (用更大 $\mathcal{D}_\ell$) $\rightarrow A^{V^k} \neq A^{V^{k-1}} \rightarrow I_t^{(k)}$ 可能 flip。随策略变强、行为策略平均 (V) 抬升，上轮 “高于平均” 的动作这轮可能 “低于新平均” → **自举式标准提升**，advantage 永远衡量 “相对当前水平的进步”，阈值按 “约 40% 为正” 自动上移及格线——这是跨多轮持续涨不饱和的引擎。

8. 实验

硬件：静态双臂 2×6 -DoF + 平行夹爪，50 Hz，3 相机。三任务族：Cafe/Box/Laundry。

标志能力：espresso 连续 13 小时；折陌生衣物 2 小时 +；装纸箱 600 秒全流程。**核心改善：**最难任务 throughput $>2 \times$ 、failure $\sim 2 \times$ **reduction**，多数任务 90%+。折衣 collar-up 严格判据 2 轮（每轮 600 条）达 97%。

数据/人力 (Appendix F)：T 恤每轮 4 机器人 300 条、2 轮、**0% intervention**；diverse laundry 450 eval + 287 correction；失败模式去除 ~ 1000 auto + (280+378) correction；box 每轮 600 demo + 360 correction（intervention 最高）；cafe 单轮 429 correction + 414 auto。

ablation：advantage conditioning 链式增益 ($\pi_{0.5} \rightarrow \pi_{0.6}$ 无 indicator $\rightarrow$ RL-pretrained $\rightarrow$ offline-RL+SFT $\rightarrow$ full RECAP)；vs AWR/PPO 远超；多轮 (Fig.9/10) T 恤首轮破 90%、长程 box 2 轮 throughput $2 \times$ ；默认 $\beta = 1$ 已达报告性能。

9. 与精读笔记的差异更正

1. **dropout** = 30%（笔记 50%）。
 2. 后训练 **advantage** 用 $N=50$ lookahead，非纯 $R_t - V$ ；纯 MC 仅预训练。
 3. 微调阈值约 40%、折衣约 10%、预训练约 30%。
 4. C_{fail} 精确值、最终 checkpoint 均未开源，引用须标“论文未给”。
-

一句话总结：把 RL 的 advantage 从“loss 通道”挪到“conditioning 通道”——分布式 MC value 把 0/1 升级成 step advantage，二值化成“Advantage: positive/negative” prefix 注入 flow VLA，靠 CFG 式 random drop 联合训双支，把 self-improving 实现为“从永久 anchor 反复重训的 advantage 加权监督学习”，避开 PPO 的 importance ratio/KL/on-policy，同时天然兼容长程（episode reward）与 flow 架构（log-likelihood 下界）。