

支撑机制：Cal-QL / RLPD / AWR / CFG

2026-06

Contents

支撑机制：Cal-QL / RLPD / AWR-AWAC / CFG	1
0. 共同前置：离线 RL 的 OOD 高估病理	1
1. CQL $\rightarrow$ Cal-QL	1
2. RLPD：四要素	2
3. AWR / AWAC (RECAP 理论近亲)	2
4. Classifier-Free Guidance (解读)	3
5. 机制总览	3

支撑机制：Cal-QL / RLPD / AWR-AWAC / CFG

本文是主报告第 2 章的全细节支撑版。PLD 依赖 Cal-QL/RLPD (离线-到-在线 RL), RECAP 依赖 AWR/AWAC + CFG (advantage 加权/条件)。每个机制给出精确目标函数与设计动机。CFG 部分论文未涵盖, 按通用文献给出, 标“(解读)”。

来源: storage_replay/S04_CalQL_2303.05479.pdf, S03_RLPD_2302.02948.pdf, pld_improvement/P07_AWAC_2006.09 P06_IQL_2110.06169.pdf。

0. 共同前置：离线 RL 的 OOD 高估病理

Bellman 备份 $\mathcal{B}^\pi \bar{Q}(s, a) = r + \gamma \mathbb{E}_{a' \sim \pi(s')} [\bar{Q}(s', a')]$ 。策略改进 $\pi(s) = \arg \max_a Q_\theta(s, a)$ 选出的 a' 落在数据外 (OOD) 时, $\bar{Q}(s', a')$ 是函数逼近器在未见区域的外推、无数据约束。 $\arg \max$ **系统性挑中被高估的 OOD 动作** $\rightarrow$ 高估经备份回传放大 $\rightarrow$ Q 单调爆炸发散。离线比在线更致命: 无法采新数据纠偏, 错误外推永不修正。三条应对: 显式保守 (CQL $\rightarrow$ Cal-QL)、隐式正则 + 架构抑制 (RLPD)、隐式策略约束 (AWR/AWAC)。

1. CQL $\rightarrow$ Cal-QL

CQL 保守目标 (Eq.3.1):

$$\min_{\theta} \underbrace{\alpha (\mathbb{E}_{s \sim \mathcal{D}, a \sim \pi} [Q_\theta] - \mathbb{E}_{s, a \sim \mathcal{D}} [Q_\theta])}_{\text{push down OOD; push up data}} + \frac{1}{2} \mathbb{E}_{\mathcal{D}} [(Q_\theta - \mathcal{B}^\pi \bar{Q})^2].$$

第一项压低当前策略 (可能 OOD) 动作 Q、抬高数据动作 Q $\rightarrow$ Q_θ 成真值下界, $\arg \max$ 不选 OOD。

Cal-QL 动机： CQL 常把 Q 压得过低（远低于真值）。在线微调时坏动作的真实回报仍高于被严重低估的离线 $Q \rightarrow$ 坏动作“看似最优” $\rightarrow$ 策略 unlearn 已学好的离线初始化 $\rightarrow$ offline-to-online 早期性能塌陷 (dip)。

校准定义 (Def.4.1)： $\mathbb{E}_{a \sim \pi}[Q_{\theta}^{\pi}(s, a)] \geq \mathbb{E}_{a \sim \mu}[Q^{\mu}(s, a)] = V^{\mu}(s)$ 。 Q 既下界真值（保守）又上界参考策略真值 V^{μ} （校准）， μ 取行为策略（ V^{μ} 由 return-to-go 回归、无 bootstrap）。

Calibrated objective (Eq.5.1)：

$$\mathbb{E}_{s \sim \mathcal{D}, a \sim \pi}[\max(Q_{\theta}(s, a), V^{\mu}(s))] - \mathbb{E}_{s, a \sim \mathcal{D}}[Q_{\theta}(s, a)].$$

$\max(Q_{\theta}, V^{\mu})$ 把 push-down 截断在 V^{μ} 以上 $\rightarrow Q$ 被保证 $\geq V^{\mu}$ ，坏动作（真实回报 $\leq V^{\mu}$ ）不再显得最优 $\rightarrow$ 消除 dip、不掉性能、加速，同时仍下界真值（保守保留）。Theorem 6.1: regret = miscalibration + overestimation 两项受控， V^{μ} 越接近 V^* 界越紧。

2. RLPD：四要素

不做离线预训练、不加显式保守项，naive SAC + replay 靠四件套既稳又高效。

① **对称采样 50/50：** 每 minibatch 一半 offline 一半 online，每步恒有 offline 转移把 Q 钉在数据区域 $\rightarrow$ 隐式正则，无需显式约束。50/50 在稀疏奖励方差最低（80/20 退化）。

② **Critic LayerNorm：** $\|Q_{\theta, w}(s, a)\| = \|w^{\top} \text{relu}(\psi_{\theta})\| \leq \|w\| \|\psi_{\theta}\| \leq \|w\|$ ， Q 被权重范数上界（即便 OOD） $\rightarrow$ 封顶外推爆炸，不用显式保守项也稳。只压数值外推、不约束探索 $\rightarrow$ 防发散又保探索。去掉它 Q 发散性能崩。

③ **Ensemble + Min-Q：** $y = r + \gamma \min_{i \in \mathcal{Z}} Q_{\theta'_i}(s', \tilde{a}')$ ，取 min = 悲观分位，抵消“max+ 函数逼近”的正向高估偏置。随机集成蒸馏（ E 个抽 $Z \in \{1, 2\}$ ）兼顾抑高估与多样性。

④ **高 UTD：** 每交互一步做 G 次梯度更新（10-20），数据反复 bootstrap $\rightarrow$ 样本效率大增。但高 UTD 对同批数据大量梯度步易过拟合/放大高估 $\rightarrow$ **必须依赖 ①②③ 才不发散**。四要素协同：UTD 提供效率，前三者提供稳定性。Cal-QL § 7.2 追高 UTD 时直接复用 RLPD 的 LayerNorm+ensemble。

3. AWR / AWAC (RECAP 理论近亲)

从带 KL 信赖域的策略改进 $\max_{\pi} \mathbb{E}_{a \sim \pi}[A^{\pi_k}]$ s.t. $D_{\text{KL}}(\pi \| \pi_{\beta}) \leq \epsilon$ 出发，KKT 解 $\pi^* \propto \pi_{\beta} \exp(A/\lambda)$ 投影回参数类得 AWR 目标 (Eq.13)：

$$\theta_{k+1} = \arg \max_{\theta} \mathbb{E}_{(s, a) \sim \mathcal{D}}[\log \pi_{\theta}(a|s) \cdot \exp(\frac{1}{\lambda} A^{\pi_k}(s, a))].$$

性质：(i) 解以 π_{β} 为基底、回归只在数据样本上做 $\rightarrow$ 结果策略天然拉向数据支撑（隐式 KL 约束）、**从不查询 OOD Q** ；(ii) advantage 用 off-policy bootstrap Q 估计、可复用任意数据；(iii) 权重直接作用于采样 (s, a) 、**无需重要性采样、无需显式拟合 π_{β}** （避免在线微调时行为模型漂移失配 $\rightarrow$ 既不过度保守又能持续改进）。

与 RECAP 异同： 共享内核（advantage 引导策略偏向高优势动作）。区别——AWR 把 advantage 压成回归权重 $\exp(A/\lambda)$ （软筛选，下采大量数据）；RECAP 把 advantage 作生成模型条件 + 推理时 CFG，可在推理期连续调控“想要多高优势”（调 β ）而无需重训。

4. Classifier-Free Guidance (解读)

要从 $p(x|c)$ 采样 (RECAP 中 x = 动作、 c = 目标 advantage), CFG 用同一网络联合训 $p_\theta(x|c)$ 与 $p_\theta(x)$ (训练时随机丢 c), 推理时外推:

$$\hat{p}(x|c) \propto p(x)(p(x|c)/p(x))^\beta, \quad \tilde{\epsilon} = \epsilon_\theta(x, \emptyset) + \beta(\epsilon_\theta(x, c) - \epsilon_\theta(x, \emptyset)).$$

$\beta > 1$ 放大条件方向, 把采样推向更强满足 c 的样本, 同时以 $p(x)$ 为底盘保证留在数据流形。 c = 高 advantage 时 = 推理时可连续调节的策略改进旋钮 (β 大 $\rightarrow$ 更 exploitative, $\beta \rightarrow 0 \rightarrow$ 退回行为先验更安全)。与 LayerNorm/隐式 KL 精神一致: 不显式查 OOD 而偏向高价值动作。random drop 保证 $p(x)$ 与 $p(x|c)$ 由同一网络一致表示, 二者之差才是有意义的条件方向。

5. 机制总览

机制	核心目标	解决	一句话
OOD 高估	$\max_a Q_\theta$ 选 OOD 外推并放大	—	离线无法纠偏, 错误自强化
CQL	push down $\mathbb{E}_\pi Q$ - push up $\mathbb{E}_\mathcal{D} Q$	OOD 高估	Q 成下界, 不选 OOD
Cal-QL	$\max(Q_\theta, V^\mu)$ 截断	CQL 过度保守 $\rightarrow$ unlearning	抬下界 $\geq V^\mu$, 不掉性能且加速
对称采样	batch 50/50	隐式正则	每步 offline 转移钉住数据区
LayerNorm min-Q 高 UTD	$\ Q\ \leq \ w\ $ $y = r + \gamma \min Q$ 每步 G 次更新	外推爆炸 maximization bias 样本效率	封顶外推不约束探索 悲观分位抵消正偏 多次备份, 须靠前三者防发散
AWR/AWAC	$\max \mathbb{E}[\log \pi \cdot \exp(A/\lambda)]$	过度保守/OOD 查询	隐式 KL 约束、off-policy、免 IS
CFG (解读)	$\hat{p} \propto p(x)(p(x c)/p(x))^\beta$	推理时可控优势引导	以行为先验为底放大优势方向