

VLA 真机后训练：四篇代表文章解读

PLD · RECAP · VLA-OPD · RL-for-VLA-Generalization

刘越（同济大学计算机学院 空间智能课题组）

2026-06

1 导读

VLA (Vision-Language-Action) 真机后训练的核心矛盾是：真机一条 rollout 30–60 秒且需人工监管，经验极贵，而直接对 VLA 跑 RL 会触发灾难性遗忘（千倍量级的梯度更新 + 稀疏奖励高方差 + 无教师锚定，使视觉/语言通用能力崩塌）。本文挑四篇代表文章，各自独立解读它们“如何把 RL 变得可行”：

- **PLD** 与 **RECAP** 是两条无 teacher 的自改进 (self-improving) 主线——一个让 RL 产物是数据，一个让 RL 信号走 conditioning 通道；
- **VLA-OPD** 是有 teacher 的蒸馏路线，用一个机制（有界 mode-seeking 的 Reverse-KL）同时拿到 SFT 的稠密与 RL 的闭环；
- **RL for VLA Generalization** 是一篇训练动力学实证，回答“SFT 与 RL 在 VLA 的不同泛化维度上各自负责什么”。

四篇放在一起，正好覆盖“自采数据 / 自算信号 / 借教师 / 机制实证”四个面。

2 PLD：用残差 RL 做“部署对齐的数据生成”

Self-Improving VLA Models with Data Generation via Residual RL (NVIDIA/CMU/UCB/UT-Austin, ICLR 2026, arXiv:2511.00091)

一句话定位。冻结 VLA 主干，用 off-policy 残差 RL 训一个轻量专家去接管 VLA 的失败状态，用“基策略探针 + 残差救场”生成一批贴着 VLA 部署分布、含纠错行为的数据，再用普通 SFT 蒸馏回 VLA。RL 的产物是数据，专家训完即弃。

核心机制。执行动作是冻结 VLA 与受限残差之和 $\bar{a} = a_b + a_\delta$, $a_b \sim \pi_b$, $a_\delta \in [-\xi, \xi]$ 。残差是结构独立的高斯策略（约 10M 参数，5 GB 显存可跑），之所以用残差而非 LoRA，是因为残差可以用任意 off-policy 算法训练（维护 replay buffer、老 rollout 反复用），且冻结主干从结构上根除遗忘。三阶段：

- **Stage 1 (Learn)**：用 Cal-QL 训 critic（保守 + 校准，避免离线 RL 的 OOD Q 高估）+ RLDP 双 buffer（offline 50% 锚定“成功长什么样” + online 50% 提供新鲜信号 + LayerNorm 封顶 Q 外推 + 高 UTD）。一条真机 rollout 进 buffer 后参与约 250k 次梯度更新——**off-policy 复用是真机可行的根本**。
- **Stage 2 (Probe, 灵魂)**：前 αT 步只让 VLA 自己走（漂进它常翻车的状态），后段残差接管救回。消融 $\alpha = 0.6$ 最优。
- **Stage 3 (Distill)**：把数据喂普通 SFT, $\mathcal{L}_{\text{SFT}} = -\mathbb{E}_{(s, a^*) \sim \mathcal{D}^{\text{PLD}}} [\log \pi_{\text{VLA}}(a^* | s)]$ 。

精髓——防遗忘机制在 Stage 2 而非 Stage 3。SFT 的梯度幅度正比于“数据分布与当前策略分布的偏离”。probing 让数据起点落在 VLA 自己的访问分布上，于是目标 a^* 与 $\pi_b(\cdot | s)$ 差异小、BC loss 初值小、梯度小、更新温和——用 KL 语言说，PLD 数据 biased toward base $\rightarrow$ SFT 诱导的

$D_{KL}(\pi' \parallel \pi_b)$ 小 $\rightarrow$ 遗忘少。这与“事后冻结参数”（如 MIFO）本质不同：PLD 从数据侧根除遗忘。蒸馏后部署零额外开销（不再需要残差）。

实验。 LIBERO 上 OpenVLA 91.8 $\rightarrow$ 99.2、 π_0 93.4 $\rightarrow$ 97.2；SimplerEnv 平均 71.8 $\rightarrow$ 96.6；真机 peg insertion 30/30, cluttered 未见物体 PLD 28/30 vs 人类数据 12/30（PLD 探针到角落状态并生成 recovery，人类/RL 数据从没访问过这些状态故卡死）。

局限。 base 必须够强（>80% 可冲 99%，<50% 救不回）；只用稀疏二元奖励；**per-task 残差，跨任务无 skill 共享**；闭环残差蒸馏进开环 chunk，高动态任务会失效；reward 仅 episode 末尾 0/1，无 step 级信用分配。

3 RECAP / $\pi^*0.6$: 把 advantage 从 loss 通道挪到 conditioning 通道

Physical Intelligence, $\pi^*0.6$: a VLA That Learns From Experience (arXiv:2511.14759, 未开源)。RECAP = RL with Experience and Corrections via Advantage-conditioned Policies。

一句话定位。 一个迭代式 offline RL 配方：用分布式 value function 把 episode 级 0/1 成功标签升级成 step 级 advantage，把 advantage 当作条件输入（conditioning）而非损失项（loss）注入策略，用 advantage 加权的纯监督学习实现自改进，完全绕开 PPO。

核心机制。 三阶段 PRETRAIN $\rightarrow$ SPECIALIZE $\rightarrow$ ITERATE，每轮采数据 $\rightarrow$ 重训 value $\rightarrow$ 重训策略。

- **value**: 每条 episode 只标 1 bit，导出 step reward（成功末步 0 / 失败末步 $-C_{fail}$ / 其余 -1 ），无折扣下成功轨迹的 MC return = $-(\text{到成功的剩余步数})$ ，value 学的就是“到成功的负剩余步数”。用 201-bin softmax + 交叉熵（分布式回归）而非 MSE——因为 return 多峰、交叉熵梯度有界对失败极端负值鲁棒；用 Monte-Carlo 而非 TD——躲开大模型 + 稀疏奖励下的 TD 发散（value 只用来算 advantage 做条件、不进反向传播，故相对信号足矣）。
- **advantage $\rightarrow$ 条件**: $I_t = \mathbb{1}[A > \epsilon_\ell]$ （后训练 advantage 用 $N = 50$ 步 lookahead，阈值 per-task 校准）。策略目标是 CFG-style 双支 $-\log \pi_\theta(a|o, \ell) - \alpha \log \pi_\theta(a|I_t, o, \ell)$ ，advantage 实现为文本 prefix “Advantage: positive/negative”（不改架构），训练时 random drop I_t 30% 联合训 conditional/unconditional 两支（省一遍 forward）。推理 $\beta = 1$ 时直接用 conditional 支（单次 forward）， $\beta > 1$ 时做 classifier-free guidance 锐化。

精髓。 (1) 每轮从 anchor π_{pre} 重训（而非增量更新）以避免多轮 drift——这是“流程侧”防遗忘，与 PLD 的“数据侧”防遗忘对照。(2) 失败 episode 不丢——既训 value（失败负样本）又以 $I_t=False$ 教策略避错；demo/correction 强制 $I_t=True$ （信任人类）。(3) 持续改进的引擎：旧数据不变，但新 value 重算 advantage 使同一 step 的 I_t 在不同轮翻转——策略不断把自己的水平当新及格线，advantage 永远衡量“相对当前的进步”。

实验。 制作意式咖啡连续 13 小时不中断、折陌生衣物 2 小时+；最难任务 throughput 翻倍以上，failure 约减半。同数据下显著优于 AWR 与 PPO。

局限。 未开源；单池只增不减、每轮从头重训，靠 PI 的集群 brute-force；episode 级 advantage 对“前 80% 子任务都对、最后装歪致整体失败”的长 episode，会把局部正确的段一并拉低。

4 VLA-OPD: 用有界 mode-seeking 蒸馏桥接 SFT 与 RL

Bridging Offline SFT and Online RL for VLA via On-Policy Distillation (HKUST-GZ, arXiv:2603.26666)

一句话定位。 把对齐重述为“在学生自生成轨迹上的稠密监督”：在学生自己 rollout 的 on-policy 状态上，用一个冻结强 teacher 的 token 级 logits 做有界 mode-seeking 的 Reverse-KL 蒸馏，同时拿到 SFT 的稠密快收敛与 RL 的闭环纠错、抗遗忘。

核心机制。三阶段闭环：学生 on-policy 采样（状态来自学生诱导分布，把失败状态纳入训练）→ 冻结 teacher 对每个时刻标注目标分布 $q_t = \pi_{tea}(a|s_t)$ （不执行、只取 logits，**无需稀疏奖励**）→ 最大化负 Reverse-KL

$$\max_{\theta} \mathbb{E}_{s \sim \pi_{\theta}} [-D_{KL}(\pi_{\theta}(\cdot|s) \parallel \pi_{tea}(\cdot|s))],$$

落到 token 级即用内禀奖励 $r_t = -\log \frac{\pi_{\theta}(a_t|s_t)}{\pi_{tea}(a_t|s_t)}$ 做 group policy gradient（学生 $\log \pi_{\theta}$ 项 stop-gradient，直接把 Reverse-KL 当 advantage）。

精髓——为什么选 Reverse-KL（熵动力学）。KL 方向决定 OOD 状态下的熵行为：**Forward-KL** (mode-covering, 连 teacher 在 OOD 的高熵犹豫一起模仿) → 熵爆炸、策略弥散；**Hard-CE** (只追 teacher top-1) → 过早熵坍塌、丧失动作多样性；**Reverse-KL** (zero-forcing) → 只承诺 teacher 最自信的主 mode、自动过滤 teacher 的 OOD 长尾不确定性，得到**有界熵**。实测 Forward-KL actor 熵冲到 ~2.0、Hard-CE 跌到 ~0.5、Reverse-KL 维持 ~1.2 的健康有界熵，对应最高最稳的成功率。

实验。LIBERO 上把 1-traj 极弱学生 (Avg 48.9%) 纯蒸馏抬到 87.4%、叠加 GRPO 达 93.4%（几乎复现 teacher 的 93.9%），收敛比 GRPO 基线快约 3×；on-policy 监督显著保住 unseen 任务能力（离线 SFT 的 unseen 性能崩溃）。

局限（与 PLD/RECAP 的根本区别）。VLA-OPD **必须有一个现成的强 teacher**——PLD 无 teacher（自采数据）、RECAP 无 teacher（advantage 自算），而 VLA-OPD 的样本效率与抗遗忘是“买”来的，前提是已存在比学生强的 expert。在多数真机场景这样的强 expert 并不存在，这是它相对无 teacher 路线最实质的劣势（论文也把“减少 teacher 依赖”列为 future work）。

5 RL for VLA Generalization: SFT 记忆、RL 泛化在 VLA 上的实证

What Can RL Bring to VLA Generalization? An Empirical Study (清华, NeurIPS 2025, arXiv:2505.19789)

一句话定位。一篇训练动力学实证：把 VLA 泛化拆成 **视觉 / 语义 / 执行** 三个正交维度各构造 OOD 测试，系统比较 SFT（行为克隆）与 RL 微调在每个维度上的泛化收益。Backbone 用 OpenVLA，环境 ManiSkill pick-and-place，稀疏奖励。

核心发现——三维度的“分工”格局（用相对下降 $P = (\text{OOD} - \text{IND})/\text{IND}$ 度量，drop 越小越泛化）：

维度	RL vs SFT	证据
视觉	基本持平	两者都不会诱导出超过训练随机化范围的视觉鲁棒性
语义	RL 明显更优	SFT 各子项 drop 约 -20%~-44%（未见物体 -23.1%、多容器 -44.2%），RL 普遍更轻
执行	RL 显著更优	差距最大：SFT 物体位姿 OOD drop -60.9%、机器人位姿 -63.5%，RL 仅 -13%~-20%

关键锚点：RL 收敛时在**训练分布上**与**最强 SFT 相当**，但在**未见物体/桌面上**高 42.6%——RL 不靠拟合训练分布取胜，而是在 OOD 上拉开差距。这是“SFT 记忆训练分布、RL 泛化到 OOD”在 VLA 上的实证。

机制解释。(1) **执行维度——轨迹分布覆盖更广：**SFT 轨迹紧贴运动规划器的单一模式成簇，RL 轨迹张成更大工作空间；遇到初始位姿偏移或中途物体重置（demo 中从未出现）时，SFT “照常推进”而失败，RL 见过更广状态分布、能从失败抓取中恢复重对准。(2) **语义维度——技能与物体解耦：**反复试错让“抓取”动作不再依赖具体物体类型，迁移到未见物体。(3) **视觉维度：**鲁棒性主要由数据增强范围决定，而非优化范式。

实践建议。先少量 SFT/warm-up 让 checkpoint 达到可优化的初始成功率，再 **PPO**——且发现 **VLA 上 PPO 稳定优于 GRPO/DPO**（机器人 POMDP 的非平稳性破坏 GRPO 的组相对优势估计，稀疏奖

励使 DPO 难分优劣)。分工：SFT 求训练分布内的基本能力，RL 专门负责语义接地与执行鲁棒，视觉鲁棒靠训练随机化解决。

与 LLM 上结论的异同。一致：SFT 记忆、RL 泛化的核心命题在具身 VLA 上成立。VLA 特有修正：
① 泛化收益**维度依赖**（视觉维度持平，非全面碾压）；② 机制是机器人特有的“轨迹覆盖 + 技能解耦 + 失败恢复”，而非 LLM 的规则/推理层面；③ LLM 当红的 GRPO 在 VLA 反而不稳，**后训练经验不能直接平移**。

6 小结

文章	范式	把 RL 变可行的方式	防遗忘	关键代价
PLD	无 teacher 自改进	RL 产物是 数据 (probing 生成对齐数据再蒸馏)	数据侧 (probing→ 小 KL)	base 须够强；per-task 残差
RECAP	无 teacher 自改进	advantage 走 conditioning 通道，监督学习消费	流程侧（每轮回 anchor 重训）	未开源；大算力；episode 级 advantage 太粗
VLA-OPD	有 teacher 蒸馏	学生 on-policy 状态上做 有界 Reverse-KL 蒸馏	on-policy 锚定当前分布	必须有现成强 teacher
RL-VLA-Gen	实证研究	(结论) RL 提语义/执行泛化，SFT 保训练分布内	—	仅仿真、仅 pick-and-place

一条贯穿四篇的主线：**SFT 负责把策略带进训练分布（求准），RL 负责在 OOD 上锐化与纠错（求泛化）**；真机的约束（rollout 极贵）逼出了 off-policy/蒸馏/conditioning 这些“不直接跑 PPO”的迂回设计，而它们共同未解决的是**失败 rollout 的 step/段级利用与长 horizon 信用分配**。

说明：RECAP、VLA-OPD 等未开源或预印本，精确常数以论文为准；arXiv 26xx.xxxxx 为整理时预印本编号，引用前请核对实际发表信息。更深的机制推导见仓库 技术报告_VLA 后训练_PLD 与 RECAP 机制解读 与 docs/A1-A3。