

VLA 真机 SFT+RL 混合训练：经验采样、存储与利用

PLD / RECAP 两条 self-improving 路线诊断 + HEARS-Buffer 数据层方案 + RL/SFT 训练
动力学机制解读

研究者：刘越（同济大学计算机学院 空间智能课题组）

2026-06

Contents

1 摘要	3
2 第一部分·诊断	3
3 为什么 VLA 真机必须 SFT+RL 混合训练	3
3.1 SFT 单独 — 2 大本质缺陷	3
3.2 RL 单独 — 3 大工程灾难	3
3.3 为什么是“灾难性”——4 因素叠加（而非单次梯度大）	3
4 四种 VLA 后训练范式对比	4
5 Buffer 必要性：rollout 成本 + 9 条件框架	5
5.1 rollout 成本决定 Buffer 形态	5
5.2 9 条件框架：何时需要存 Episode	5
6 第二部分·PLD 与 RECAP 深读	6
7 PLD 深度解读：三阶段 + 双 Buffer + ICLR 审稿	6
7.1 三阶段流水线	6
7.2 双 Buffer 机制（继承 RLPD 四件套）	6
7.3 ICLR 2026 审稿意见 + 9 条件打分	6
8 RECAP / $\pi \times 0.6$ 深度解读	7
8.1 三阶段与“每轮 from pretrain 重训”	7
8.2 数据池、reward 与 step-level label	7
8.3 π 训练（CFG-style 双支）	7
8.4 数据流对比 PLD	8
9 第三部分·综合评价与 HEARS-Buffer	8
10 综合评价 + 8 条 Buffer 设计原则	8
10.1 三个独立 lens 殊途同归	8
10.2 8 条 Buffer 设计原则（需求侧 9 条件 $\leftrightarrow$ 能力侧 8 原则）	8
11 HEARS-Buffer 设计方案	9
11.1 三层架构 $\times$ 五支柱	9
11.2 Pillar C ★：段级 SFT+RL 混训（核心创新）	10
11.3 段级标注 $\rightarrow$ Action Expert 训练接口	11
11.4 工程要点	11

12 验证路径与 Roadmap	11
12.1 为什么强制先复现 PLD + RECAP	11
12.2 四 Phase Roadmap (6 个月)	11
12.3 风险登记 (最重要 5 个)	12
12.4 诊断部分总结 (5 句话)	12
13 第四部分·训练动力学机制	12
14 RL/SFT 训练动力学机制解读	12
14.1 核心对立: SFT 「记忆/压缩」 vs RL 「探索/扩展」	12
14.2 分布层面: sharpening vs expansion, 及 “RL 是否扩展边界” 之争	13
14.3 梯度与 token 层面	13
14.4 熵动力学	13
14.5 灾难性遗忘与 OOD: RL 如何 “修复” SFT (核心 takeaway)	13
14.6 何时用 SFT / RL / 混合	13
14.7 对 VLA 真机后训练的启示	14
15 附: 关键文献	14

1 摘要

本报告聚焦 VLA (Vision-Language-Action) 真机后训练这一核心工程瓶颈：真机 RL 一条 rollout 需 30–60 秒并需人工监管，经验数据极贵，“怎么采、怎么存、怎么用”决定了 self-improving VLA 能否落地。报告分三部分：

1. **诊断 (第 1–5 章)**：论证为什么 VLA 真机必须 SFT+RL 混合训练（灾难性遗忘的 4 因素叠加机制），对比四种后训练范式，并用「9 条件框架」量化“何时必须存经验”，进而深读两条 self-improving 主线——PLD（数据驱动）与 RECAP / $\pi \cdot 0.6$ （信号驱动）。
2. **方案 (第 6–8 章)**：用三个独立视角（学术审稿 / 工业顾问 / 9 条件框架）评价 PLD 与 RECAP，归纳 8 条 Buffer 设计原则，提出 **HEARS-Buffer**——self-improving VLA 训练范式的“第 4 个组件：数据层基础设施”，其核心创新是段级 SFT+RL 混训 (Pillar C)，并给出 6 个月验证路径。
3. **机制 (第 9 章)**：独立的 RL/SFT 训练动力学机制解读，综合 30+ 篇调研与 2025–2026 最新研究，从分布、梯度、熵、遗忘四个层面回答“SFT 与 RL 在物理上到底改变了什么”，并迁移到 VLA。

一句话结论：VLA 后训练应是「SFT 求覆盖（求准）→ 在 OOD 峰附近切 RL 求锐化与修复（求泛化），全程显式管熵、用 off-policy replay 缓解 rollout 成本」；而当前 PLD/RECAP 在“失败 rollout 段级利用、跨任务 skill 复用、Buffer 主动管理、运行时检索”四处留有结构性空白，正是 HEARS-Buffer 的切入点。

2 第一部分·诊断

3 为什么 VLA 真机必须 SFT+RL 混合训练

核心论点：SFT 单独不够、RL 单独更糟。VLA 真机直接 RL 会触发“灾难性遗忘”断崖——通用能力 95% → 50%。LLM/VLM 已用 RLHF+KL 锚定解决，但 VLA 中尚无共识方案，这正是后续四范式都“绕开直接 RL VLA”的根本原因。

3.1 SFT 单独 — 2 大本质缺陷

- **分布漂移 / 误差累积 (Compounding Error)**：训练只见专家轨迹的 state；部署偶然偏离 → 进入未见 state → 错误累积爆炸。**加数据无效**——示教覆盖不到“机器人卡桌角”这类 OOD 状态。
- **模仿天花板 (Imitation Ceiling)**：70% 示教训出 70% 模型，**永远不超过示教者**；平均拟合所有示教（含失败轨迹），**不能利用失败数据**，浪费一半信息。

3.2 RL 单独 — 3 大工程灾难

- **显存 + 真机样本不可承受**：直接 fine-tune VLA $\approx$ 62 GB 显存；真机 rollout 30–60 秒/条 + 人工 reset，纯 RL 需百万 rollout $\approx$ 86 天 24/7 真机，工程不可行。
- **Cold-Start 困境**：初期策略全失败 (reward = 0)，梯度信号为零；PPO/GRPO 漂移 25k 步仍学不到有效行为。经验判据：SFT 成功率 < 20% 时，PPO/GRPO 基本学不动。
- **灾难性遗忘 ★ (VLA 关键顾虑)**：多步梯度更新洗掉 VLA 的视觉/语言通用能力 → “酸奶专精白痴”。LLM/VLM 用 PPO+KL 锚定 (RLHF/DPO) 已广泛验证可控，但 VLA 既要保视觉又要保语言，KL 系数定不下来——**这是个 open problem**。

3.3 为什么是“灾难性”——4 因素叠加（而非单次梯度大）

#	对比维度	SFT	RL (真机 VLA)
1	梯度更新次数	150 步 (50 示教 $\times 3$ epoch)	250,000 步 $\rightarrow$ 1,600 $\times$
2	梯度方向准确性	精准 (loss 直指 a^*)	高方差 (reward 延迟, 50 步动作同等 “强化”)
3	早期学习信号	每步都有	前 99 条全失败 = 0 信号 ; 第 100 条成功 $\rightarrow$ 大梯度爆炸
4	是否有教师锚定	$\checkmark a^*$ 锚定	$\times$ 无标准答案 (最大化 reward $\rightarrow$ reward hacking)

量化效果 (纯 RL 1000 rollout 后): 识别红色物体 95% $\rightarrow$ **50%**; 理解 “往左挪一点” 90% $\rightarrow$ **30%**; 任务成功 60% $\rightarrow$ 99% (任务学好了, 但通用能力没了)。

本章结论: SFT 负责下限 + RL 负责上限。4 因素叠加下, VLA 直接 RL 是 open problem—
—下一章看四范式如何各自应对。

4 四种 VLA 后训练范式对比

PLD / RPD / VLA-OPD / RECAP 四个工作的 teacher、loss、关键 trick 完全不同, 但都在 “绕开直接 RL VLA”: PLD 冻结 + 残差; RPD 训新小模型; VLA-OPD KL 锚定; RECAP 把 RL 信号塞 conditioning 通道。

维度	PLD (ICLR 2026)	RPD (IROS 2026)	VLA-OPD (HKUST GZ)	RECAP / $\pi^*0.6$ (PI, 2025.11 NEW)
目的	VLA self-improving	VLA $\rightarrow$ 轻量 student	强 expert $\rightarrow$ 升级 VLA	VLA 从经验学习
Teacher	无 (自己采)	VLA 自己	必须外部强 expert	无 (advantage 自己算)
被训对象	残差 MLP(10M)+ 蒸馏回 VLA	全新小模型 100M	VLA backbone	VLA backbone
是否需 reward	$\checkmark$ 0/1 sparse	$\checkmark$ PPO 需要	$\times$ 不需要	$\checkmark$ 0/1 episode 标签 (最弱信号)
RL 算法	Cal-QL (off-policy)	PPO (on-policy)	Pure PG (on-policy)	无 PPO/REINFORCE (二值 advantage conditioning)
Loss 核心	Cal-QL Q + actor	PPO + MSE distill	Reverse-KL distill	CFG-style 双支 BC
推理时	VLA forward	小 student forward	VLA forward	VLA double forward + CFG
Replay buffer	$\checkmark$ 双 buffer	$\times$	$\times$	$\times$ (单池 BC 形式)
显存需求	5 GB (RTX 4090)	中等	大 (VLA 全 FT)	大 (multi-GPU 集群必需)
灾难性遗忘风险	低 (冻结 VLA)	无 (新模型, 但失多任务)	中 (KL 锚定)	低 (每轮 from π_{pre} 重训)

维度	PLD (ICLR 2026)	RPD (IROS 2026)	VLA-OPD (HKUST GZ)	RECAP / $\pi^*0.6$ (PI, 2025.11 NEW)
真机战绩	Peg insertion 100%, 4-stage 1h	~95% LIBERO, 50Hz	~95% LIBERO	折衣 2h+, espresso 13h 连续, failure 50% ↓

一句话定位: PLD = 用残差 RL 生成 “分布对齐” 数据再 SFT 蒸馏; RPD = 用 VLA 当 teacher, PPO+MSE 训轻量 student; VLA-OPD = 用强 RL expert 当 teacher 升级 VLA; RECAP = success/failure 二值标签 → advantage 二值化 → 推理时 CFG 引导。

本章结论: PLD 和 RECAP 是当前 self-improving 双主线; 4 范式都未解决长 horizon 端到端 / 失败 rollout 段级利用 / 跨任务 skill share / Buffer 主动管理。

5 Buffer 必要性: rollout 成本 + 9 条件框架

5.1 rollout 成本决定 Buffer 形态

是否需要 buffer 由 rollout 成本决定, 如何用 buffer 由真机数据稀缺度决定。

- 仿真 1 秒/rollout → 重采便宜, 不需存 (RPD)。
- 真机但有强 expert → expert 替你采, 也不需自己存 (VLA-OPD)。
- 真机无 teacher → 必须存 (PLD + RECAP)。真机 60 秒/rollout, 相对仿真是 $3,600\times$ 。

只有 PLD 落在最严苛假设 (真机 + 无 teacher + 要求样本效率), 所以用双 buffer 50/50 对称采样 + Cal-QL UTD=20, 把每条 rollout 榨干约 $250\times$ 。RECAP 同样真机但 PI 有大算力, 故用单池只增不减 (粗放但简单)。

5.2 9 条件框架: 何时需要存 Episode

把 “是否需要存 Episode” 形式化为 9 条件, 三层结构, 作为后续评 PLD/RECAP 的统一标尺:

- ** 层 1 · 必要条件 (不满足则完全不需要存) **
 - #1 Rollout 成本高: rollout 成本 ÷ 梯度更新成本 > 100。真机机器人 √, LLM 数学题 ×。
- ** 层 2 · 充分条件 (任一满足即值得存) **
 - #2 Long horizon (单 episode > 50 步 + 跨步依赖) | #3 Continual learning (部署后持续学习 > 1 周) | #4 环境非平稳 (光照/物体/任务会变) | #5 非马尔可夫 (当前决策依赖过去状态)
- ** 层 3 · 放大条件 (决定 buffer 设计复杂度) **
 - #6 任务集合开放 | #7 多任务 | #8 端测容量受限 (设备存储 < 100 GB) | #9 检索影响 decision (检索 vs 不检索性能差 > 5%)

本章结论: 后续将用这 9 条件量化检验 PLD (1/9) 和 RECAP (1-2/9), 证明二者的结构性空白并非单一视角 bias。

6 第二部分·PLD 与 RECAP 深读

7 PLD 深度解读：三阶段 + 双 Buffer + ICLR 审稿

PLD (Probe-Learn-Distill, ICLR 2026, arXiv:2511.00091) = 三阶段整合。起点 60%、终点 99%、热身 50 条。Stage 2 Probing 是 PLD 的灵魂，防遗忘根本机制就在这里。

7.1 三阶段流水线

π_{VLA} (60%) + 50 条示教

- Stage 1 [Probe+Learn]: 冻结 VLA + 残差 RL
- Stage 2 ★ [Probing]: 让 VLA 先掉坑再救 (采集分布对齐数据)
- Stage 3 [Distill]: 普通 SFT 蒸馏回 VLA
- π'_{VLA} (99%) 可重复 (Self-Improving Loop)
- **Stage 1 (工程基础)**: 冻结 VLA backbone (结构性防遗忘) + 外挂残差 MLP (10M, 非 LoRA) + 残差动作 clip 在 $[-\xi, \xi]$ + Cal-QL warmup critic. **5 GB 显存可跑**, 60% → 99% 约 250k 步。
- **Stage 2 ★ (灵魂)**: 时间步 $0 \rightarrow \alpha T$ 让 VLA 单独走 (probing 探险), $\alpha T \rightarrow T$ 让 (VLA + 残差) 接管救场。 **α 消融: $\alpha=0 \rightarrow 95\%$ / $\alpha=0.6 \rightarrow 99.5\%$ ★ / $\alpha=1 \rightarrow 94\%$** 。反直觉点: 不 probing 直接采会毁了 VLA (数据只覆盖最优区域, 部署飘到边缘就崩)。
- **Stage 3 (看似普通 SFT)**: $\mathcal{L}_{\text{SFT}} = -\mathbb{E}_{(s, a^*) \sim D^{\text{PLD}}} [\log \pi_{\text{VLA}}(a^* | s)]$ 。防遗忘根本机制在 Stage 2 而非 Stage 3——Stage 2 把数据分布调到 $\approx$ VLA 现有分布 → SFT loss 小 → 梯度小 → 不灾难性遗忘。这是与 MIFO (事后冻结参数) 的本质区别: PLD 是事前避免。

7.2 双 Buffer 机制 (继承 RLPD 四件套)

PLD 的双 Buffer 完全沿用 RLPD (Ball et al., ICML 2023, arXiv:2302.02948), 创新在 Stage 2/3 而非 buffer 本身。

- **架构**: Offline Buffer B_{off} (50 条示教, 永久固定, 提供“成功长什么样”的**锚定**) + Online Buffer B_{on} (FIFO 滚动, 提供“现在在哪探索”的**新鲜**)。各取 128 → Batch(256) → Cal-QL update (UTD=20)。
- **四件套**: 对称采样 50/50 + LayerNorm critic + Ensemble (10 Q 取 Min-Q 保守估计) + 高 UTD (20)。改动: Offline 源改为 VLA 自跑、critic 改 Cal-QL、actor 改 Residual MLP。
- **三个易被低估的关键**: ① **50/50 是 sweet spot** (80/20、20/80 都退化); ② **LayerNorm 不可省**——否则 Cal-QL 在 OOD action 上 Q 值发散到天文数字, 很多复现失败都因漏掉它; ③ **$250 \times$ 样本利用 = 高 UTD $\times$ Ensemble Min-Q**, 把“86 天真机数据”压成可行工程。
- **Residual + 双 Buffer 是一对**: 残差 MLP 是独立 Gaussian 策略 → 可 off-policy 复用历史数据; 若改用 LoRA → 必须 on-policy → 数据用完即丢 → 双 buffer 失去意义。

三大结构性劣势: ① **Flat Structure** (所有 transition 平等存储, 无时序/任务标签/失败模式聚类); ② **被动累积不感知漂移** (FIFO 不区分“过时失败”与“当前失败”); ③ **Per-Task 不共享** (90 个 LIBERO 任务 → 90 个独立 buffer + 90 个 residual MLP, 0 skill share)。

7.3 ICLR 2026 审稿意见 + 9 条件打分

4 位审稿人独立指出 4 大不足, 与 9 条件框架**两个独立 lens 殊途同归**:

审稿人	质疑要点	对应 9 条件
yzFS	任务增长需多少 specialist? skill 能否跨任务复用?	#6 + #7
F1ZL	多任务下残差策略是否每任务 独立训练?	#7

审稿人	质疑要点	对应 9 条件
BWyM	评估仅短 horizon, 未测长 horizon / 时序依赖	#2 + #5
wXQ9	仅二值 reward 限制效率; 训练 closed-loop 但蒸馏后 open-loop chunking	dense reward + 闭/开环

9 条件覆盖度 = 1/9: 仅满足必要条件 #1 (rollout 高效复用), #2-#9 全 ×。根因——PLD 双 buffer 的设计目标是“训练时如何高效复用 rollout”，而非“部署后如何应对环境变化与持续学习”。

8 RECAP / $\pi^*0.6$ 深度解读

RECAP / $\pi^*0.6$ (Physical Intelligence, Sergey Levine 团队, 2025.11, arXiv:2511.14759, 未开源) 是第二条主线——**信号驱动** (vs PLD 数据驱动)。

一句话: RECAP = 用 value function 把 episode-level reward 升级到 step-level advantage, 再用 advantage 作为 conditioning + CFG 推理, **绕开 PPO** 实现 self-improving。

8.1 三阶段与“每轮 from pretrain 重训”

阶段	名字	频率	输出
A	PRETRAIN	一次性	$V_{\text{pre}}, \pi_{\text{pre}}$ (数万小时多机器人数据)
B	SPECIALIZE	每新任务一次	π_{ℓ}^0 (demo 微调起点)
C	ITERATE	每任务 K 轮	π_{ℓ}^* (采数据 → 重训 $V \rightarrow$ 重训 $\pi \rightarrow$ 循环)

反直觉设计: 阶段 C 每轮 V 和 π 都从 $V_{\text{pre}}/\pi_{\text{pre}}$ **重训** (非增量更新) ——增量会忘掉通用预训练知识, 每轮 from pretrain = 把预训练当永久 anchor。

8.2 数据池、reward 与 step-level label

单池 $\mathcal{D}_{\ell}$ 只增不减, 三来源: $\mathcal{D}_{\text{demo}} + \mathcal{D}_{\text{auto}}$ (含失败) + $\mathcal{D}_{\text{correction}}$ (HG-Dagger 人接管)。每条 episode 仅标 1 bit success/failure, reward:

$$r_t = \begin{cases} 0 & t = T \text{ 且 success} \\ -C_{\text{fail}} & t = T \text{ 且 failure} \\ -1 & \text{otherwise} \end{cases}$$

Value function 学到的物理含义 = 负的“剩余步数到成功”, 归一化到 $[-1, 0]$ 。**Step-level advantage indicator I_t 规则:** demo / correction **强制 $I_t = \text{True}$** (绕过 V 评估, 视为理想动作); autonomous 成功段 $I_t = \mathbb{1}[A > \epsilon_{\ell}]$; autonomous 失败段保留 (学“这种动作不好”)。

8.3 π 训练 (CFG-style 双支)

$$\min_{\theta} \mathbb{E} [-\log \pi_{\theta}(a_t | o_t, \ell) - \alpha \log \pi_{\theta}(a_t | I_t, o_t, \ell)]$$

第一项 = unconditional BC, 第二项 = conditional BC。工程要点: ① 二值化阈值 $\epsilon_\ell = \text{demo value}$ 分布 **30 percentile** (per-task 自校准); ② advantage 通过 **prefix 文本注入** (“Advantage: positive/negative”), **模型架构完全不动**; ③ **Random drop I_t (50%)** 等价随机 conditional/unconditional 双支, 无需算两遍 forward; ④ 推理时换 positive/negative prompt forward 两次 = CFG, $\hat{\pi} \propto \pi \cdot (\pi_c/\pi)^\beta$ ($\beta = 1$ 单次足够); ⑤ **多轮迭代的微观机制**: 旧 episode 数据不变, 但新 V^k 重算 advantage $\rightarrow$ 同一 step 的 I_t 可能 flip, 这是 “持续改进” 的来源。

8.4 数据流对比 PLD

维度	PLD	RECAP
筛选	Stage 2 Probing 主动选 200–300 条高质量	不筛选 , 全收 (数千 episode/task, brute-force)
利用	双 buffer 50/50 + Cal-QL UTD=20 (250 $\times$ 复用)	单池累积 + 4 label 规则 + 每 轮 from π_{pre} 重训
存储	offline 50 永久 + online FIFO 1M	单池只增不减 (无压缩/归 档/遗忘, 推测单 task 100 GB+)

PLD 用更少数据 (200–300 + 50); RECAP 用更多 (折衣 600 / 装盒 1200, 37.5% 含 expert intervention), 换来长 horizon 连续运行 + 免 probing + 工业直接适用。

9 第三部分·综合评价与 HEARS-Buffer

10 综合评价 + 8 条 Buffer 设计原则

10.1 三个独立 lens 殊途同归

评价 lens	PLD	RECAP
学术审稿	ICLR 2026, 4 审稿独立指出 4 大不足	未走审稿, 社区认可高, 尚未 被独立审视
工业顾问	5 GB 消费级友好; 但 “1h autonomous” 是 state machine 拼接	13h espresso 最强; 但整 episode 算 advantage, “局 部正确但最终失败” 的段被一 刀切
9 条件覆盖	1/9	1–2/9

四个共同空白 (证明非单视角 bias): ① 失败 rollout 段级利用; ② 跨任务 skill share; ③ Buffer 主动管理; ④ 推理时 Retrieval。

10.2 8 条 Buffer 设计原则 (需求侧 9 条件 $\leftrightarrow$ 能力侧 8 原则)

#	原则	对应条件	核心机制	依赖库
①	智能筛选	#1,#4	embedding 到 centroid 距离 + TD-error + new-cluster 三级判定	VLA backbone
②	段级切分	#2,#5	subtask prediction $\hat{\ell}$ 变化 + advantage 突	VLA backbone
③	失败样本利用 ★	业界建议	变/intervention 段级 quality 标 + 失败段 KNN 找 recovery target 朝相似成功段 SFT	FAISS
④	存储空间上界	#8	size cap + per-cluster quota + archived ref-only	LeRobot v3.0
⑤	数据压缩	#8	3 层	ffmpeg, Pastoret
⑥	主动遗忘 ★	#3,#4	Frame/Segment/Clip 周期 capability check + archive + 复发 trigger	新设计
⑦	跨任务复用	#6,#7	embedding + HDBSCAN 增量聚类 + skill_id 倒排索引	hdbscan, FAISS
⑧	运行时检索	#9	FAISS HNSW + KNN top-k	FAISS

两个 take-away: 8 条中 6 个可基于成熟开源库; 仅 ③⑥ 是全新设计点 (段级混训 + 主动遗忘), 研究差异化集中于此。三概念精确区分——**新颖度** (到 centroid 距离) 决定是否写入; **质量标注** (段内平均 advantage) 决定 SFT/RL 权重; **库内对比** (KNN match) 决定 bad 段 recovery target。

11 HEARS-Buffer 设计方案

研究定位: HEARS (Hierarchical Episodic Adaptive Retrieval Skill-library Buffer) 不是又一个 self-improving 算法或 VLA 模型, 而是该训练范式的第 4 个组件——**数据层基础设施**, 可 plug-in 进 PLD 也可进 RECAP (**互补而非竞争**)。

11.1 三层架构 × 五支柱

顶层 · 操作 API 层 write / sample / retrieve / evict / snapshot

└ 同时服务 Action Expert 训练 + 推理

中层 · 索引层 (5 支柱, 核心研究贡献) A② B⑦ C★③ D④⑤⑥ E⑧

底层 · 存储层 (LeRobot v3.0, 不重新发明) Parquet + MP4 + Parquet meta

└ 3 层压缩 → 10 task 长期部署 6–10 GB (端测可行)

支柱	名字	原则	核心机制	解决条件
A	Episodic + Segment-aware	②	LeRobot v3.0 + segment metadata	#2,#5
B	Cross-task Skill Library	⑦	HDBSCAN 在 VLA visual embedding 聚类 (espresso/cappuccino 共享 “磨豆” “压粉”)	#6,#7
C★	Mixed SFT+RL Segment Annotation	③	失败 rollout 段级混训	#1 升级
D	Capability-aware Lifecycle	④⑤⑥	cluster SR 评估 + 主动归档/遗忘 + 复发触发	#3,#4,#8
E	Retrieval-augmented Decision	⑧	FAISS HNSW + KNN (v0.3+)	#9

底层可靠性: episodes/ 是 source of truth, segments/clusters/faiss 索引层可从原始数据完全重建。

11.2 Pillar C ★: 段级 SFT+RL 混训 (核心创新)

动机 (业界顾问关键建议): 长程任务 sparse reward 信号粗。一条 espresso 失败 episode (500 步) 可能磨豆/压粉都对、只是装手柄歪了, 整条被当负样本 $\rightarrow$ 学偏。**bad rollout 用来纠偏, good rollout 用来强化与探索。** 现有所有范式都没显式处理 “局部正确但最终失败” 的段 (PLD 直接丢失失败 / RECAP 整 episode advantage 被全局失败拉低 / 14 篇 replay 论文都是 step-level 无 segment 概念)。

C1 段切分 (4 信号融合 cut score):

$$\text{cut_score}(t) = w_1|A(t)-A(t-1)|+w_2|V(t)-V(t-1)|+w_3\mathbb{1}[\hat{\ell}(t) \neq \hat{\ell}(t-1)]+w_4\mathbb{1}[\text{intervention}]$$

推荐 $w_1=0.3, w_2=0.3, w_3=0.2, w_4=0.5$ (**intervention boundary 权重最高**——expert 接管/松手是 ground-truth 级段边界)。滑窗 5 步、平均 > 0.6 切分。

C2 段级 quality 标注 (3 类):

Quality	判据	SFT_w	RL_w	用法
good	段内平均 $A > \epsilon_\ell + V$ 上升	0	1.0	RL 强化 + entropy 探索
bad	段内平均 $A < 0 + V$ 下降 + episode 失败	1.0	0	SFT 朝 recovery target
unclear	介于两者	0.3	0.3	弱双修

核心特例规则: autonomous + 失败 episode + 段内 $A > 0 \rightarrow \text{quality} = \text{good}$ 。这就是 “局部正确但最终失败” 的段——RECAP 整 episode advantage 被全局失败拉低, **HEARS 段级 advantage 能识别局部正确。**

C3 Recovery target 匹配 (KNN): 对每个 bad 段取起始 state 的 visual embedding $\rightarrow$ 在 quality=good 段库 FAISS HNSW KNN top-5 (约束: 距离 $< \theta$ + 同 cluster 优先 + 同 task 优先) $\rightarrow$ 训练时随机抽 1 作 SFT target (防过拟合)。

11.3 段级标注 → Action Expert 训练接口

落到 Action Expert (flow matching VLA, 如 π_0) 的统一 loss:

$$\mathcal{L}_\sigma = \text{SFT}_w \cdot \mathcal{L}_{\text{BC}}(\sigma, \text{recovery_target}) + \text{RL}_w \cdot \mathcal{L}_{\text{flow-adv}}(\sigma, I_{\text{advantage}})$$

- $\mathcal{L}_{\text{BC}} = -\mathbb{E}_{(o,a) \in \sigma} [\log \pi(a_{\text{target}}|o)]$ (BC 朝 KNN recovery target)
- $\mathcal{L}_{\text{flow-adv}} = \text{flow matching MSE} + \text{advantage prefix conditioning}$ (借用 RECAP lower bound)
- **batch 按 segment 而非 episode 取样**, Random drop I_t (CFG) 仍适用。

创新三合一 = RECAP advantage conditioning (推理 trick 反用于训练) + 业界顾问段级混训建议 + KNN recovery 朝相似成功段 SFT。Buffer 段级标注 ↔ Action Expert 训练端**端到端可微**。

11.4 工程要点

- **底层 LeRobot v3.0** (vs RLDS: Parquet+MP4 支持 append、视频压缩、HF 生态原生, Open-VLA/ π_0 已迁移)。
- **3 层压缩**: Frame (MP4 H.264, 10×) → Segment (unclear 丢/bad 留 keyframes/good 全留, ~60% 保留) → Cluster (归档老 cluster 保留 centroid+5 representatives, 90% 压缩)。**100 GB → 6–10 GB**。
- **D 支柱复发触发**: archive 只删数据保留 centroid, 新段距 archived centroid 近时自动 revive (类比人类 “提取性遗忘”, Recall failure not storage failure)。
- **入库流程 ~3s/episode** (远低于 rollout 30–60s): value forward 算 advantage → changepoint 切段 → quality 标 → embedding → HDBSCAN 增量聚类 → bad 段查 recovery → 写 LeRobot → 异步 capability check。

12 验证路径与 Roadmap

12.1 为什么强制先复现 PLD + RECAP

HEARS 是数据层基础设施、本身非 self-improving 算法, **必须有 baseline 算法的 rollout 数据才能验证价值**: ① 对照实验 baseline; ② 提供 rollout 数据集 (C 支柱段切分在其 rollout 上做 PoC); ③ 参考实现来源 (RECAP advantage conditioning + CFG 是训练接口的直接借鉴)。

12.2 四 Phase Roadmap (6 个月)

Phase	内容	时长	资源	风险	验收
0a PLD 复现	ICLR 开源代码 + LIBERO-Long 10 task	4 周	1× RTX 4090	低	SR ≥ 95%; 产出 200–300 rollout/task
0b RECAP 复现	从 arXiv 重建 Algorithm 1 + Eq.1/3/4, 用 π_0 替 $\pi_{0.6}$	8 周	4–8× A100	高 (PI 不开源)	advantage cond + CFG 跑通, vs π_0 +10% SR
1 HEARS C 支柱 PoC	段切分 + Recovery KNN + 段级 loss	4 周	1–2× A100	中	段切分 F1 > 0.7, quality 准确率 > 75%

Phase	内容	时长	资源	风险	验收
2 HEARS 完整集成	5 支柱接进 PLD/RECAP, 4 setup ablation + 论文	8 周	4-8× A100	中	HEARS+PLD vs PLD baseline SR 提升 ≥ 3%

关键里程碑：4w PLD baseline / 12w RECAP baseline / 16w C 支柱 PoC / **24w 论文 draft**。Phase 0b 备选：Plan B 只复现 value function（4 周，用作段切分判据）；Plan C 等 PI 开源（2026 H2）。目标会议：CoRL 2026（9 月 deadline）/ ICLR 2027。

12.3 风险登记（最重要 5 个）

#	风险	概率	严重	缓解
R2	RECAP 复现工程量超估	高	高	Plan B 只复现 V；Plan C 等开源
R7	GPU 资源不足（0b/2）	高	中	申请集群；LoRA 替代 full FT
R3	HDBSCAN 聚不出有意义 cluster	中	高	退回 K-Means + subtask label 监督
R4	段切分 4 信号权重难调	中	中	Grid search + 100 gold standard 校准
R6	段级 SFT/RL 混训不稳定	低	高	借鉴 RECAP random drop；逐渐加 RL weight

两个红色风险（高概率 + 高严重）= R2（RECAP 复现）与 R7（GPU 资源），是项目最大瓶颈。

12.4 诊断部分总结（5 句话）

1. SFT/RL 单独都救不了 VLA（纯 RL 1000 rollout 后识别红色 95%→50%、任务 60%→99% 但通用能力丢失），必须混合训练。
2. 已有两条路线：PLD（数据驱动，残差 RL 生成对齐数据再蒸馏）+ RECAP（信号驱动，value function 生成训练信号直接 FT），都很强但都有结构性短板。
3. 3 个 lens 综合评价（学术审稿 + 工业顾问 + 9 条件框架）共同识别 4 个空白。
4. HEARS-Buffer 5 支柱(A Episodic / B Skill / **C Mixed SFT+RL★** / D Lifecycle / E Retrieval) 对应 8 设计原则，C 支柱配 Action Expert 训练接口。
5. 6 个月验证路径：先复现 PLD+RECAP baseline，再 HEARS PoC，目标 CoRL 2026。

13 第四部分·训练动力学机制

本章为独立机制解读，为前三部分的工程选择提供“为什么”的理论支撑：为什么 SFT 与 RL 必须混合、为什么 RL 能修复 SFT 遗忘、为什么必须显式管熵。综合本地调研 30+ 篇与 2025–2026 最新研究。

14 RL/SFT 训练动力学机制解读

14.1 核心对立：SFT「记忆/压缩」vs RL「探索/扩展」

源头是 [SFT Memorizes, RL Generalizes (arXiv:2501.17161, ICML 2025)]: SFT 倾向记住训练分布、OOD 即崩；结果奖励训练的 RL 能跨规则/视觉变体泛化。但这句口号已被 2025 下半年研究反复修正，需区分三层：

层面	SFT 在做什么	RL 在做什么
目标	最大化专家轨迹似然	最大化期望奖励 $E[R]$
数据来源	off-policy (固定专家数据)	on-policy (自身采样 rollout)
分布效果	扩张/同质化 (覆盖更多 mode)	压缩/锐化 (集中到高奖励 mode)
熵	不直接约束, 常使熵升高/漂移	系统性降低熵 (探索预算被消耗)
风险	OOD 遗忘、格式锁死	熵坍塌、mode collapse

物理直觉: SFT 把概率质量铺到老师走过的所有路径上 (拟合更宽分布); RL 把质量从错误路径抽走、堆到对的路径上 (再分配, 不创造新路径)。二者方向相反, 这是它们互补又互相覆盖的根因。**关键澄清:**「SFT 记忆、RL 泛化」是现象级总结而非机制真理——SFT 的问题不在“记忆”而在“OOD 早峰后遗忘”, RL 很大程度是“修复”而非凭空泛化 (见下)。

14.2 分布层面: sharpening vs expansion, 及“RL 是否扩展边界”之争

- **RL Squeezes / SFT Expands** [arXiv:2509.21128]: RL 把推理功能集中到少数关键 step, SFT 均摊到许多 step。参数层面对偶——MIFO [arXiv:2510.04454]: **SFT 更新冗余幅度大、RL 更新节俭幅度小**, 故后续 SFT 会覆盖先前 RL, 需参数冻结保护。
- **争议 (须向导师呈现两面):** 观点 A [arXiv:2504.13837, NeurIPS 2025] —— pass@1 RL 胜 base, 但 **pass@k (大 k) base 反超**, RL 可解集是 base 子集, **只提采样效率不创造新模式**; 观点 B [ProRL, arXiv:2505.24864] —— 长程 RL + KL 控制 + 参考重置能解 base 全失败的问题, **扩展边界。调和:** 决定 RL 是“锐化”还是“扩展”的开关, 是**探索预算 (熵) 是否被维持**。

14.3 梯度与 token 层面

- **SFT 隐含坏 reward** [DFT, arXiv:2508.05629, ICLR 2026]: 标准 SFT 梯度 $\equiv$ 隐式奖励 $1/p(y|x)$ 的策略梯度——越不确定的 token 被赋越大奖励 (逆概率加权、无界方差), 这是泛化差的根因。修正一行: $\text{loss} = -p.\text{detach}() \cdot \log p$, 使 SFT 接近 RL 泛化。
- **负梯度 = 锐化动力** [arXiv:2505.18830]: 对错误路径施加负梯度产生 squeezing effect, 把质量从错误 mode 抽走——SFT 只有正梯度 (只抬对的、不压错的), 做不到。
- **统一视角** [UPGE/HPT, arXiv:2509.04419]: SFT、PPO、GRPO 是同一策略梯度估计器的特例, SFT 是“优势恒 +1、无负样本”的退化 RL。

14.4 熵动力学

[The Entropy Mechanism, arXiv:2505.22617]: 无干预 RL 中策略熵早期急剧下降、探索枯竭。经验定律 $R = -a \cdot e^H + b$ ——**性能用熵“换”**, 天花板在熵耗尽前可预测。**熵就是 RL 的探索预算**, 花光就跳不出当前 mode (这是“常规 RL 只锐化”的微观解释; ProRL 能扩展正因避免熵过早耗尽)。熵还可作 SFT/RL 判别信号: [SRFT, arXiv:2506.19767] 用熵区分“SFT 全局漂移 vs RL 细粒度优化”动态调权。

14.5 灾难性遗忘与 OOD: RL 如何“修复”SFT (核心 takeaway)

[RL Fine-Tuning Heals OOD Forgetting in SFT, arXiv:2509.12235]: 真相不是“SFT 记忆/RL 泛化”, 而是 **OOD 性能在 SFT 早期达峰, 随后随 ID 优化而遗忘; RL 在恢复被遗忘的能力**。谱分析: 遗忘 = 权重矩阵奇异向量旋转 (方向丢了), 奇异值基本不变 (幅度没丢)。限制: RL 只能从有限范围的 SFT checkpoint 修复——**SFT 过度了救不回来**, 呼应 [Quagmires, arXiv:2510.01624] “高 SFT 分数会误导你”。**结论: SFT 别练过头, 在 OOD 峰附近就切 RL。**

14.6 何时用 SFT / RL / 混合

场景	该做什么
连格式都不对、0 奖励率高 已有格式、要泛化	先 SFT 稳定格式（SFT 是 RL 前提） 切 RL
想长期边界扩展	长程 RL + 维持熵（KL 控制 + 参考重置）
最小改动提升 SFT 泛化	DFT 一行替换

三类自动切换信号：熵触发（SRFT）| 梯度范数 + 散度触发（SASR, arXiv:2505.13026）| rollout 正确率触发（HPT）。趋势从“两阶段顺序”→“单 step 双梯度统一 loss”（CHORD, arXiv:2508.11408, 已并入 ms-swift）。

14.7 对 VLA 真机后训练的启示

1. 「RL 修复 SFT 遗忘」更关键——VLA 的 SFT 同样 OOD 早峰后遗忘, 换光照/物体就崩; [Continual VLA via RFT, arXiv:2602.10503], [VLA-OPD, arXiv:2603.26666] 均报告 on-policy RL 比 SFT 抗遗忘。
2. 熵坍塌在动作空间更危险——连续动作熵坍塌 = mode collapse 到单一抓取姿态; VLA-OPD 用有界 mode-seeking 目标避开熵爆炸/坍塌。
3. rollout 极贵 → 必须 off-policy + replay——这是 PLD 走 off-policy、本报告主张 HEARS replay 的根本动因。
4. 梯度不对称 → 参数保护 + token 级重加权（DFT + RLSD 方向/幅度解耦可迁移到动作 token）。
5. 不能只看 loss/成功率均值——必须看 OOD 成功率与多样性指标。

一句话：VLA 后训练应是「SFT 求覆盖（求准）→ 在 OOD 峰附近切 RL 求锐化与修复（求泛化），全程显式管熵、用 off-policy replay 缓解 rollout 成本」。完整文献与机制细节见仓库 docs/01_训练动力学机制解读.md。

15 附：关键文献

VLA 后训练范式：PLD (Xiao et al., ICLR 2026, arXiv:2511.00091) | RECAP/ $\pi \times 0.6$ (Physical Intelligence, 2025.11, arXiv:2511.14759) | RLPD (Ball et al., ICML 2023, arXiv:2302.02948) | Cal-QL (Nakamoto et al., NeurIPS 2023, arXiv:2303.05479) | VLA-OPD (arXiv:2603.26666)。

训练动力学完整文献见第 9 章末尾「参考文献」。

基础设施：LeRobot v3.0 | HDBSCAN | FAISS。